ETL con PostgreSQL

Este documento describe el flujo de datos para la Extracción, Transformación y Carga (ETL) de datos vectoriales, desde un entorno local basado en PostgreSQL hasta la plataforma de análisis y consumo de Inteligencia Artificial en la nube de Azure.

1 CREACIÓN DE BD Y CARGA DE DATOS EN POSTGRESQL

El objetivo es crear una Base de Datos Vectorial (pgvector) y cargar las imágenes del dataset FER2013. Para ello, utilizaremos **Docker**, que tiene un contenedor con el servidor **PostgreSQL** y la extensión **pgvector** preinstalados.

1.1. CREACIÓN DE LA BASE DE DATOS Y LA TABLA

DESCARGA Y EJECUCIÓN DEL CONTENEDOR DOCKER (Pgvector)

Usaremos la imagen ankane/pgvector.

1. **LIMPIEZA (Opcional):** Si tienes un contenedor previo llamado 'mi_postgres_pgvector' o el puerto 5433 en uso, elimínalo:

   ```
   docker stop mi_postgres_pgvector
   docker rm mi_postgres_pgvector
   ```

2. **EJECUTAR EL CONTENEDOR:** Ejecuta el siguiente comando en una sola línea en tu Terminal (PowerShell). Usamos el puerto **5433** en el host para evitar conflictos.

   ```
   docker run -e POSTGRES_USER=<usuario> -e POSTGRES_PASSWORD=<contraseña>
   -e POSTGRES_DB=<nombre de la bd> --name <nombre del contenedor> -p 5433:5432
   -d ankane/pgvector
   ```

   Esto tambien se puede hacer desde Docker Desktop. Para ello buscamos la imagen y luego iniciamos le contenedor con la misma configuracion que por comando.

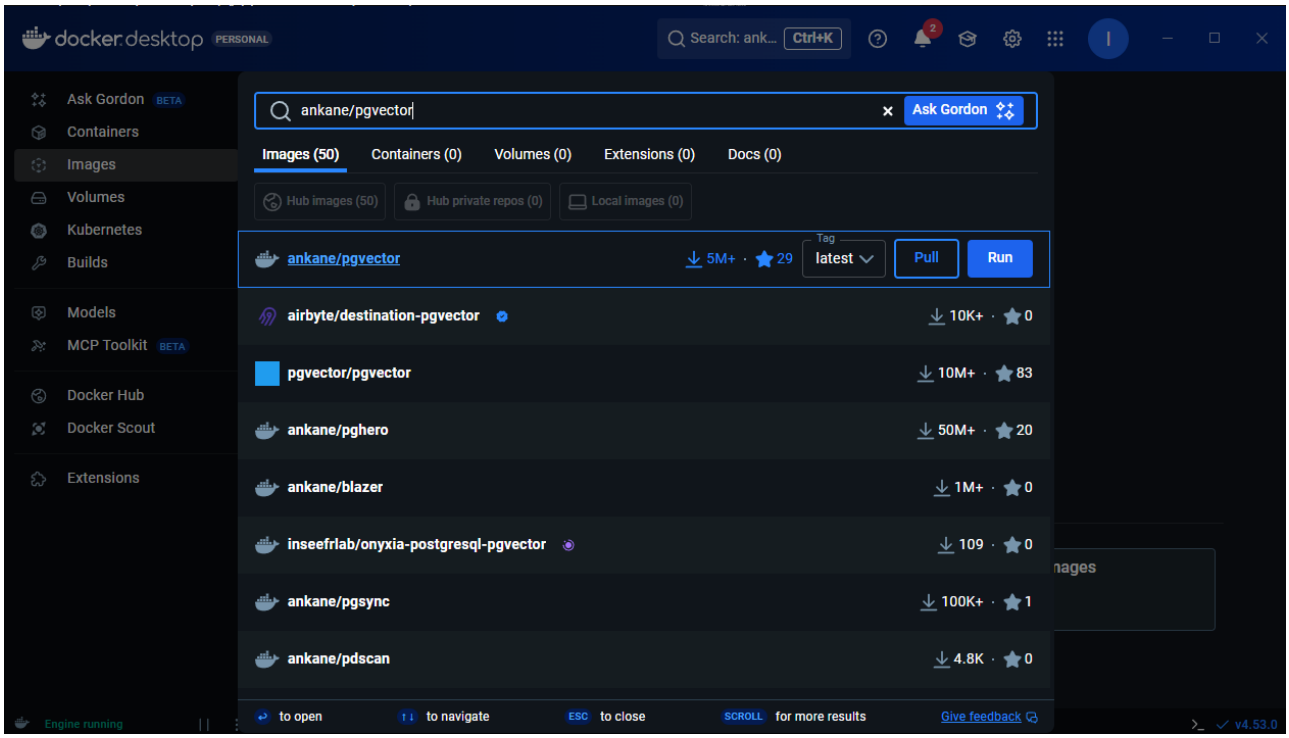
docker desktop PERSONAL
Search: ank... Ctrl+K
Ask Gordon BETA
Containers
Images
Volumes
Kubernetes
Builds
Models
MCP Toolkit BETA
Docker Hub
Docker Scout
Extensions
ankane/pgvector
Ask Gordon
Images (50)
Containers (0)
Volumes (0)
Extensions (0)
Docs (0)
Hub images (50)
Hub private repos (0)
Local images (0)
ankane/pgvector 5M+ 29 Tag latest Pull Run
airbyte/destination-pgvector 10K+ 0
pgvector/pgvector 10M+ 83
ankane/pghero 50M+ 20
ankane/blazer 1M+ 0
inseefrlab/onyxia-postgresql-pgvector 109 0
ankane/pgsync 100K+ 1
ankane/pdscan 4.8K 0
to open
to navigate
ESC to close
SCROLL for more results
Give feedback
Engine running
v4.53.0

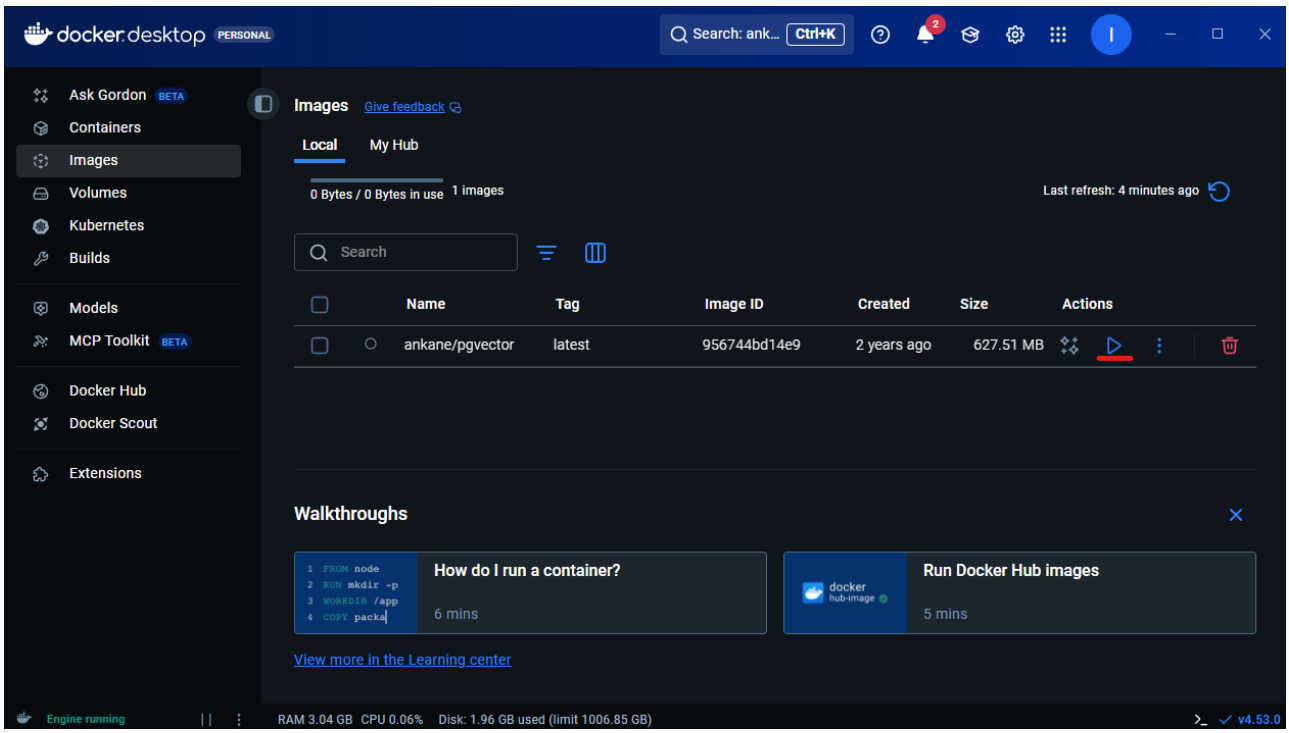
docker desktop PERSONAL
Search: ank... Ctrl+K
Ask Gordon BETA
Containers
Images
Volumes
Kubernetes
Builds
Models
MCP Toolkit BETA
Docker Hub
Docker Scout
Extensions
Images
Give feedback
Local
My Hub
0 Bytes / 0 Bytes in use
1 images
Last refresh: 4 minutes ago
Search
Name
Tag
Image ID
Created
Size
Actions
ankane/pgvector
latest
956744bd14e9
2 years ago
627.51 MB
Walkthroughs
How do I run a container?
6 mins
Run Docker Hub images
5 mins
View more in the Learning center
Engine running
RAM 3.04 GB CPU 0.06% Disk: 1.96 GB used (limit 1006.85 GB)
v4.53.0

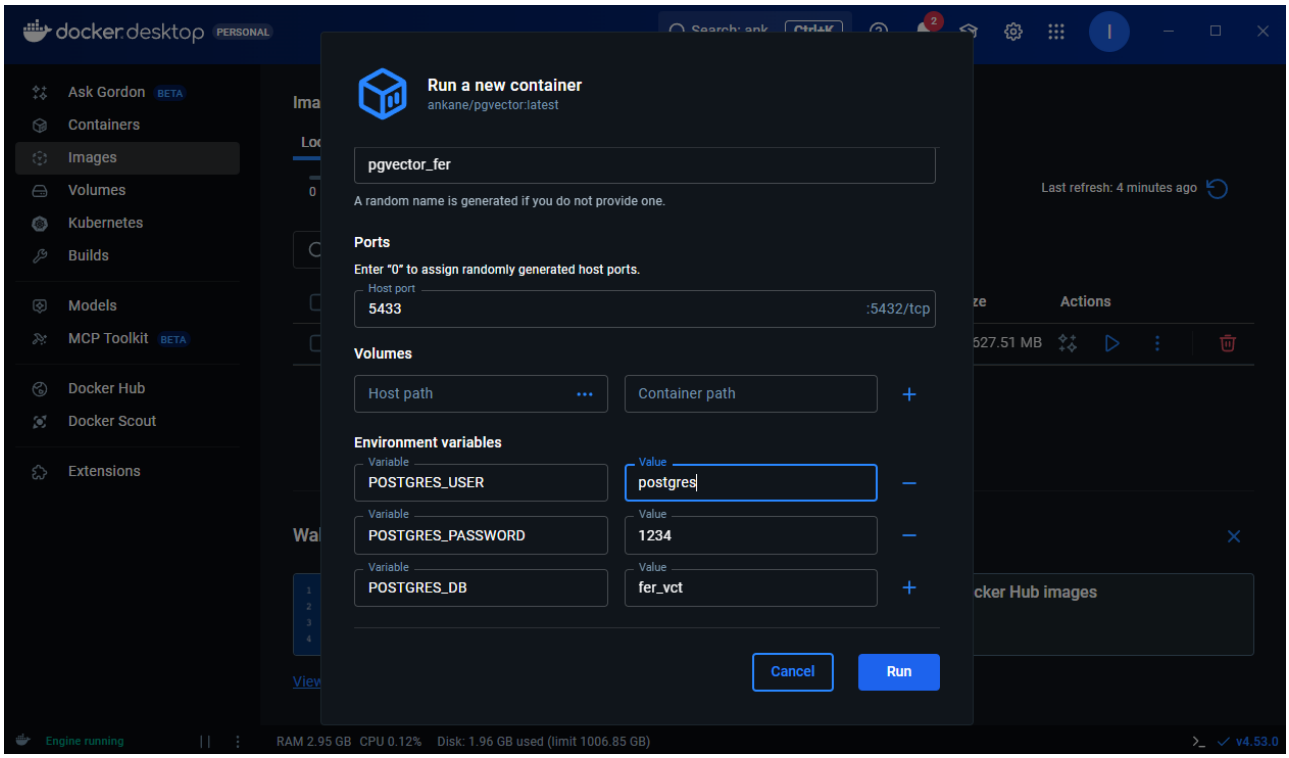

DETALLES DE CONFIGURACIÓN

- Puerto de tu PC (Host): `5433` (u otro en el que no este alojado ya algun servidor en postgreSql)
- Usuario/Contraseña: <Tu usuario> / <Tu contraseña>
- Base de datos creada: `fer_vct`

HABILITACIÓN DE LA EXTENSIÓN PGVECTOR

Una vez que el contenedor está corriendo, la extensión debe activarse en la base de datos:

1. **CONECTAR A LA CONSOLA (Terminal):**

```
    docker exec -it <nombre del contenedor> psql -U <usuario> -d <nombre de la bd>
```

2. **EJECUTAR SQL:** En 'fer_vct=#', escribe:

```
    CREATE EXTENSION vector;
```

(Escribe \q y Enter para salir)

CONEXIÓN DESDE PGADMIN 4 Y CREACIÓN DE LA TABLA

1. **CONEXIÓN EN PGADMIN:** Crea un nuevo servidor con la siguiente configuración:
    - Host name/address: `localhost`
    - Port (Puerto): `5433` (u otro en el que no este alojado ya algun servidor en postgreSql)
    - Username: <Tu usuario>

- Password: <Tu contraseña>

2. **CREACIÓN DE LA TABLA:** Una vez conectado a la base de datos 'fer_vct', ejecuta este SQL en la Query Tool. Usaremos 512 dimensiones, un tamaño común para embeddings generados por modelos como ResNet.

```sql
CREATE TABLE imagenes_fer (
    id bigserial PRIMARY KEY,
    filepath VARCHAR(255) NOT NULL, -- Ruta o nombre del archivo original
    emotion VARCHAR(50) NOT NULL, -- Etiqueta de emoción (ej: Feliz, Triste)
    vector VECTOR(512) -- Columna que almacenará el vector numérico
);
```

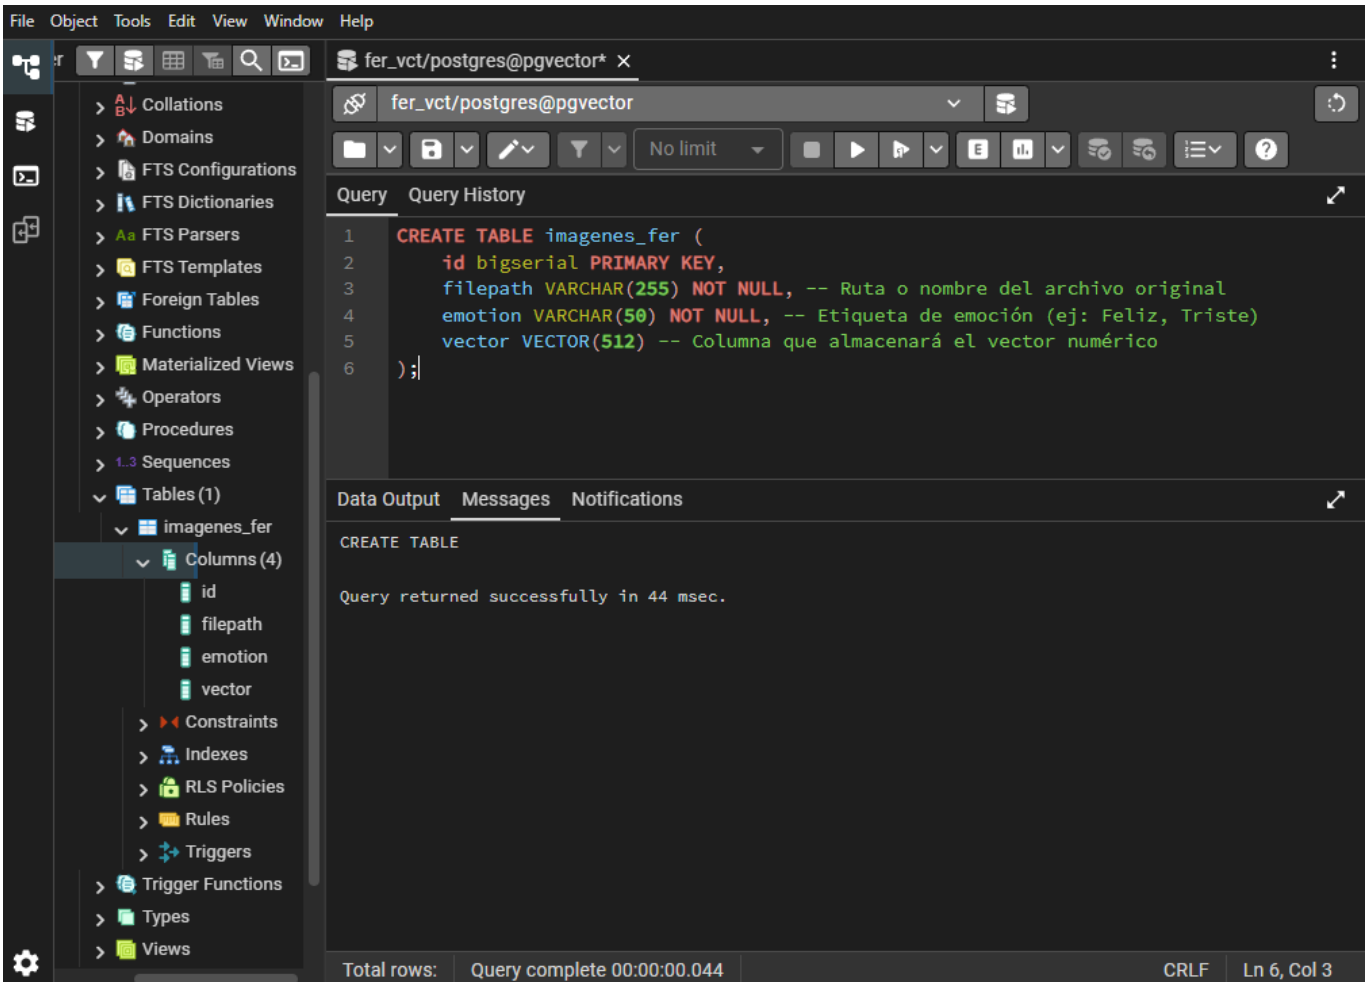

1.2. CARGA DE DATOS VECTORIALES (EMBEDDINGS)

EXPLICACIÓN DEL PROCESO DE CARGA

La base de datos vectorial solo almacena **vectores numéricos**, no imágenes. Por lo tanto, el proceso requiere un script de Python que:

1. Utilice un **Modelo de Deep Learning pre-entrenado** (como ResNet) para extraer las características de cada imagen.
2. Convierta esas características en una **lista de 512 números (el embedding)**.

3. Utilice la librería **psycopg2** para enviar ese vector a la columna VECTOR(512) de PostgreSQL.

DATASET FER2013

El código está adaptado para procesar este dataset de expresiones faciales:

Enlace al Dataset: https://www.kaggle.com/datasets/msambare/fer2013/data

SCRIPT DE PYTHON (cargar_fer.py)

1. **INSTALAR LIBRERÍAS:**

```
pip install psycopg2-binary numpy torch torchvision
```

2. **SCRIPT:** Guarda el siguiente código como 'cargar_fer.py'. **¡IMPORTANTE!** Reemplaza la variable RUTA_DATASET con la ubicación real de tu carpeta 'train'.

```
import psycopg2
import torch
from torchvision import models, transforms
from PIL import Image
import os
import glob


# ¡IMPORTANTE! Reemplaza esto con la ruta donde está tu carpeta 'train' del
dataset FER2013
RUTA_DATASET = 'C:/Ruta/A/Donde/Descargaste/fer2013/train'

DB_PARAMS = {
    'dbname': 'fer_vct',
    'user': 'postgres',
    'password': '1234',
    'host': 'localhost',
    'port': '5433'
}

# --- 1. CONFIGURACIÓN DEL MODELO DE EMBEDDING (ResNet18) ---
model = models.resnet18(weights=models.ResNet18_Weights.IMAGENET1K_V1)
model.fc = torch.nn.Identity()
model.eval()

transform = transforms.Compose([
    transforms.Grayscale(num_output_channels=3),
    transforms.Resize(256),
    transforms.CenterCrop(224),
    transforms.ToTensor(),
    transforms.Normalize(mean=[0.485, 0.456, 0.406], std=[0.229, 0.224, 0.225]),
])
```

```
# --- 2. CONEXIÓN E INICIO ---
try:
    conn = psycopg2.connect(**DB_PARAMS)
    cur = conn.cursor()
    print("Conexión a la base de datos pgvector exitosa.")
except Exception as e:
    print(f"Error al conectar a la base de datos: {e}")
    exit()

# --- 3. PROCESAR IMÁGENES E INSERTAR VECTORES ---
total_images = 0
for emotion_folder in os.listdir(RUTA_DATASET):
    emotion_path = os.path.join(RUTA_DATASET, emotion_folder)

    if os.path.isdir(emotion_path):
        for img_path in glob.glob(os.path.join(emotion_path, '*.png')):

            try:
                # 1. Cargar y Transformar
                img = Image.open(img_path)
                input_tensor = transform(img)
                input_batch = input_tensor.unsqueeze(0)

                # 2. Generar el Vector
                with torch.no_grad():
                    embedding = model(input_batch).squeeze().numpy()

                # 3. Preparar para la DB
                vector_para_db = embedding.tolist()
                relative_filepath = os.path.join(emotion_folder,
os.path.basename(img_path))

                # 4. Insertar en pgvector
                insert_query = """
                INSERT INTO imagenes_fer (filepath, emotion, vector)
                VALUES (%s, %s, %s);
                """
                cur.execute(insert_query, (relative_filepath, emotion_folder,
vector_para_db))
                total_images += 1

            except Exception as e:
                print(f"Error procesando {img_path}: {e}")
                continue

# --- 4. FINALIZAR TRANSACCIÓN ---
conn.commit()
cur.close()
conn.close()
print(f"--- Proceso Finalizado ---")
print(f"Total de imágenes procesadas e insertadas: {total_images}")
```

EJECUTAR EL SCRIPT

Navega a la carpeta del archivo 'cargar_fer.py' en tu Terminal y ejecuta:

```
python cargar_fer.py
```

2. Ingesta y Migración Inicial a la nube

Esta fase cubre la migración de la base de datos local 'fer_vct' a Azure Database for PostgreSQL - Flexible Server. Se utilizarán las herramientas nativas de PostgreSQL: `pg_dump` y `pg_restore`.

1. PRERREQUISITOS IMPORTANTES

- **HERRAMIENTAS**: pg_dump y pg_restore deben estar accesibles desde tu terminal. Si no lo están, usa la ruta completa del ejecutable (Ej: "C:\Program Files\PostgreSQL\18\bin\pg_dump.exe").
- **FIREWALL DE AZURE**: La IP pública de tu máquina debe estar permitida en las reglas de Firewall de tu servidor Azure.
- **CREDENCIALES**: Ten a mano el Host Name, Usuario Administrador (<AZURE_ADMIN>) y la Contraseña de tu servidor de Azure.

2. EXPORTAR LA BASE DE DATOS LOCAL (pg_dump)

Se crea un archivo de respaldo en la carpeta donde hemos creado.

COMANDO DE EXPORTACIÓN:

```
    <RUTA_A_PG_DUMP> -h localhost -p 5433 -U postgres -Fc -d fer_vct >
fer_vct_backup.dump
```

3. PREPARACIÓN EN AZURE POSTGRESQL

Primero tenemos que haber desplegado el servicio de Azure Sql for PostgreSQL. En la version de postgre, podremos la misma que tenemos en local.

Basics Networking Security Tags Review + create

Create an Azure Database for PostgreSQL flexible server. Learn more

Did you know that new users in Azure can use PostgreSQL flexible server free for up to 750 hours using Azure free account?
Learn more

Project details

Select the subscription to manage deployed resources and costs. Use resource groups like folders to organize and manage all your resources.

Subscription * : Azure for Students

Resource group * : (New) etl_postgres
Create new

Server details

Enter required settings for this server, including picking a location and configuring the compute and storage resources.

Server name * : pgvector

Region * : Sweden Central

PostgreSQL version * : 18 (new version)

Workload type :
- (•) **Dev/Test**
- ( ) **Production**

This instance is intended for development use outside of a production environment.

Compute + storage :
Burstable, B2s
2 vCores, 4 GiB RAM, 32 GiB storage, P4 (120 IOPS)
Geo-redundancy : Disabled
Configure server

Availability zone : No preference

Business Critical (High Availability)

Deploy a standby replica for automatic failover capability. We recommend high availability for all production workloads.
Learn more

Zonal resiliency :
- (•) Disabled (99.9% SLA)
- ( ) Enabled (99.99% SLA) - Provisions standby in a different zone than primary, fails deployment if multi-zone capacity is unavailable in region.

[ ] Allow primary and standby in the same zone when multi-zone capacity is unavailable. You will be notified when capacity becomes available so you can migrate to zone-redundant HA option.

Authentication

Select the authentication method you would like to support for accessing this PostgreSQL server. Enabling PostgreSQL password authentication allows you to authenticate with user names and passwords that are stored inside PostgreSQL.

Enabling Microsoft Entra authentication allows you to create user names in PostgreSQL, which are mapped to accounts stored in Microsoft Entra ID. Users or applications authenticated against Microsoft Entra ID, can retrieve tokens that are presented to PostgreSQL as their corresponding time-limited password. Learn more

Authentication method :
- ( ) PostgreSQL authentication only
- ( ) Microsoft Entra authentication only
- (•) PostgreSQL and Microsoft Entra authentication

Microsoft Entra administrator :
inigo.desilva@tajamar365.com
Admin Object/App ID:a6986abf-3c06-4314-b7db-2663c67ac536
Set admin

Administrator login * : postgres

Password * : ••••••••••••••••

Confirm password * : ••••••••••••••••

Estimated costs

Compute USD 29.05/month
Standard_B2s (2 vCores) 29.05

Storage USD 4.38/month
32 GiB (USD 0.14 per GiB) 32 x 0.14

Bandwidth
Outbound data transfer across services in different regions will incur additional charges. Any inbound data transfer is free. Learn more

Estimated total USD 33.43/month

Prices are just estimates and may not reflect the final price. View Azure pricing calculator.
Final charges will appear in your local currency in cost analysis and billing views.

Luego en la seccion de `Networking` vamos a marcar las casillas que estan marcadas en la imagen y vamos a añadir nuestra ip publica para poder acceder desde nuestro equipo.

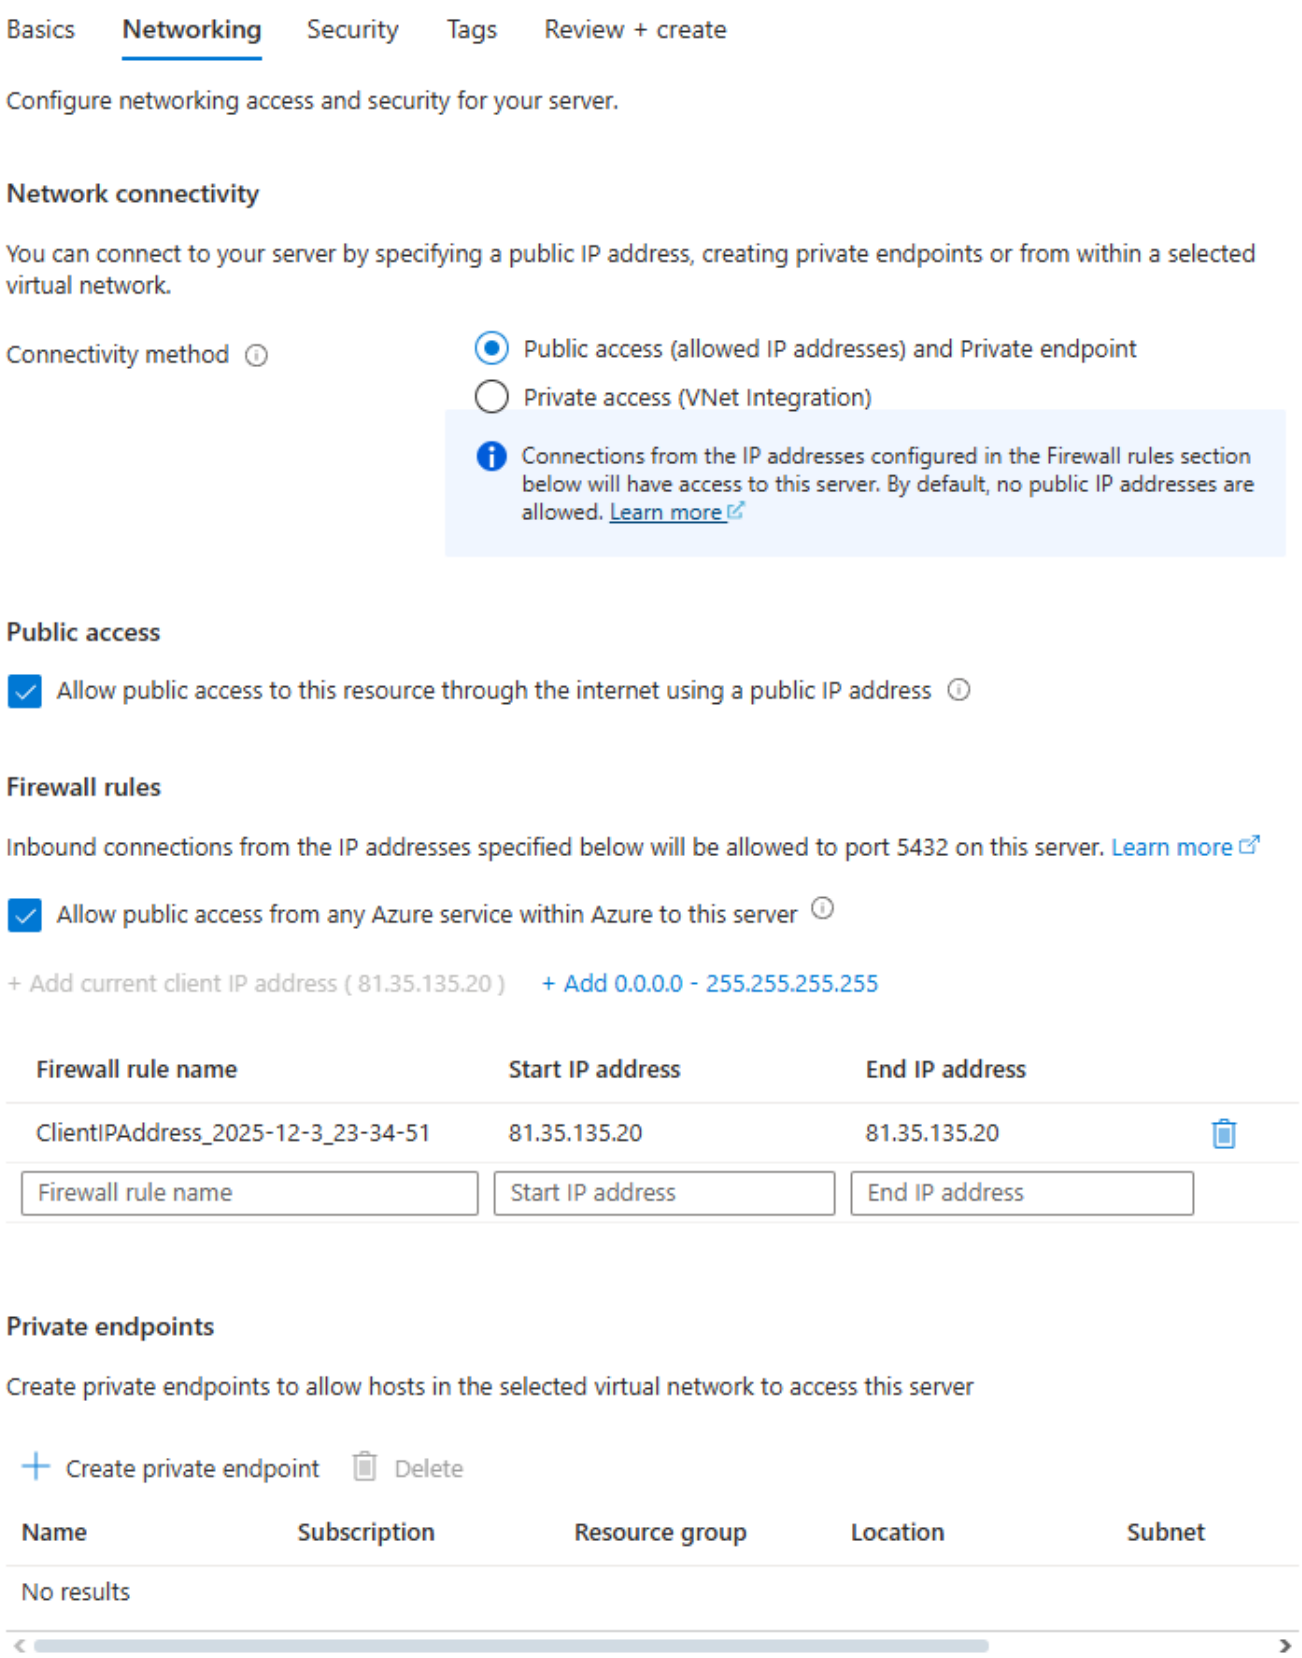

PERMITIR LA EXTENSIÓN EN EL PORTAL DE AZURE (IMPORTANTE)

Tienes que modificar un parámetro del servidor para indicarle a Azure que el usuario administrador puede habilitar esta extensión (pgvector). Este paso es obligatorio en Azure Flexible Server.

1. NAVEGA AL SERVIDOR: Ve al Portal de Azure y selecciona tu servidor PostgreSQL llamado pgvector.
2. PARÁMETROS DEL SERVIDOR: En el menú de la izquierda, busca y selecciona Parámetros del servidor (o Parameters).
3. BUSCA AZURE.EXTENSIONS: En el campo de búsqueda de parámetros, escribe azure.extensions.
4. AÑADE VECTOR: Selecciona `VECTOR` en la columna `Value`
5. HAZ CLIC EN GUARDAR (SAVE): Haz clic en Guardar en la parte superior para aplicar los cambios en la configuración del servidor.

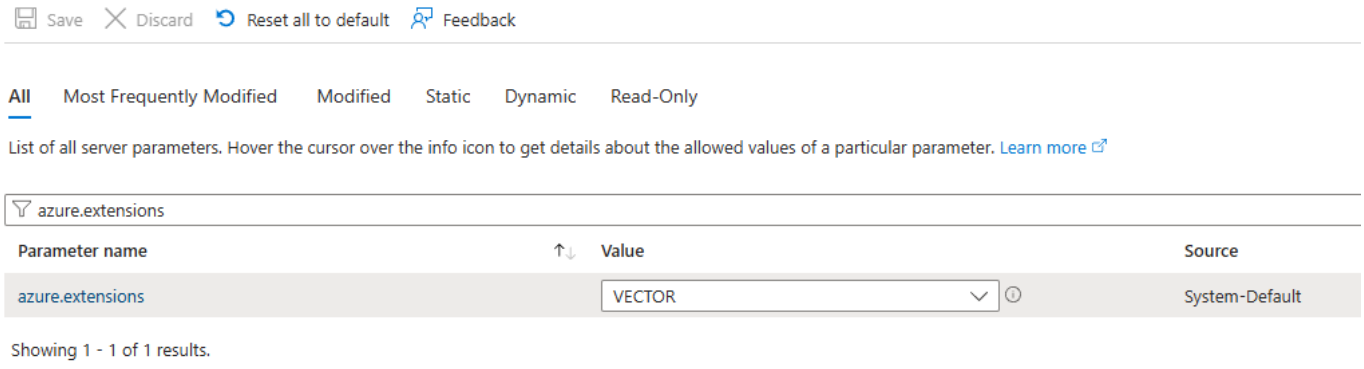

Desde la terminal del portal de Azure vamos nos vamos a conectar a nuestro servidor y a habilitar la extensión pgvector (**IMPORTANTE**):

```
psql -h <AZURE_HOST_NAME> -p 5432 -U <AZURE_ADMIN> -d <NOMBRE_DB_AZURE>

CREATE EXTENSION vector;
```

```
PS /home/inigo_desilva> psql -h pgvector.postgres.database.azure.com -p 5432 -U postgres -d postgres
Password for user postgres:
psql (16.10, server 18.0)
WARNING: psql major version 16, server major version 18.
         Some psql features might not work.
SSL connection (protocol: TLSv1.3, cipher: TLS_AES_256_GCM_SHA384, compression: off)
Type "help" for help.

postgres=> CREATE EXTENSION vector;
CREATE EXTENSION
postgres=> \q
PS /home/inigo_desilva>
```

4. IMPORTAR LA BASE DE DATOS A AZURE (pg_restore)

Utiliza pg_restore para cargar el archivo .dump en la base de datos de Azure (*esto se hace desde la terminal en local no desde Azure*).

COMANDO DE IMPORTACIÓN:

```
    <RUTA_A_PG_RESTORE> -h <AZURE_HOST_NAME> -p 5432 -U <AZURE_ADMIN> -d
<NOMBRE_DB_AZURE> -v "<RUTA_ABSOLUTA_AL_DUMP>"
```

```
C:\Users\Íñigo>"C:\Program Files\PostgreSQL\18\bin\pg_restore.exe" -h pgvector.postgres.database.azure.com -p 5432
-U postgres -d postgres -v "C:\Users\Íñigo\Downloads\borrar\BD_vectorial_FE\fer_vct_backup.dump"
pg_restore: conectando a la base de datos para reestablecimiento
Contraseña:
pg_restore: ejecutando SELECT pg_catalog.set_config('search_path', '', false);
pg_restore: creando EXTENSION «vector»
pg_restore: creando COMMENT «EXTENSION vector»
pg_restore: creando TABLE «public.imagenes_fer»
pg_restore: creando SEQUENCE «public.imagenes_fer_id_seq»
pg_restore: creando SEQUENCE OWNED BY «public.imagenes_fer_id_seq»
pg_restore: creando DEFAULT «public.imagenes_fer id»
pg_restore: procesando datos de la tabla «public.imagenes_fer»
pg_restore: ejecutando SEQUENCE SET imagenes_fer_id_seq
pg_restore: creando CONSTRAINT «public.imagenes_fer imagenes_fer_pkey»
```

5. VERIFICACIÓN

Conéctate a la DB de Azure para confirmar la migración. Esto lo podemos hacer o desde la shell de Azure o podemos conectarnos desde PostgreSQL en local, con la ruta de Azure.

Verificar conteo de filas:

```
SELECT COUNT(*) FROM imagenes_fer;
```

3. Orquestación y Procesamiento (Azure Data Factory)

Esta fase utiliza Azure Data Factory (ADF) como la herramienta de orquestación y movimiento de datos (ELT). ADF es responsable de extraer los embeddings vectoriales desde la base de datos PostgreSQL en Azure y cargarlos en el Data Lakehouse (Azure Data Lake Storage Gen2), sirviendo como el motor de la "T" (Transformación/Movimiento) y la "L" (Carga).

IMPORTANTE: MIGRACIÓN DE IMÁGENES A LA NUBE (AZURE BLOB STORAGE)

Este es un paso manual o con script que se realiza una sola vez para mover las 28,000 imágenes desde tu PC local a un servicio de almacenamiento en la nube de Azure.

1. **CREAR UN RECURSO DE ALMACENAMIENTO:** En el Portal de Azure, crea una nueva **"Storage account"** (Cuenta de Almacenamiento) si aún no tienes una separada para archivos temporales (Nota: puedes usar la misma cuenta de tu Data Lakehouse, pero es mejor separarla para claridad).
2. **CREAR UN CONTENEDOR:** Dentro de esa cuenta de almacenamiento (o tu cuenta de Data Lakehouse ADLS Gen2), crea un **"Container"** (Contenedor) para las imágenes de origen (ej., `origen-imagenes-fer`).
3. **SUBIR LAS IMÁGENES:** Sube las carpetas del dataset FER2013 (la carpeta `train/` con sus subcarpetas de emociones) a este nuevo contenedor. Puedes usar herramientas como:
    - **Azure Storage Explorer (Recomendado):** Es una aplicación gratuita de Microsoft que permite arrastrar y soltar carpetas enteras a Azure Blob Storage, manteniendo la jerarquía.
    - **Azure CLI:** Usando el comando `az storage blob upload-batch`.

Una vez que las imágenes están en la nube, el flujo ETL se vuelve nativo de Azure.

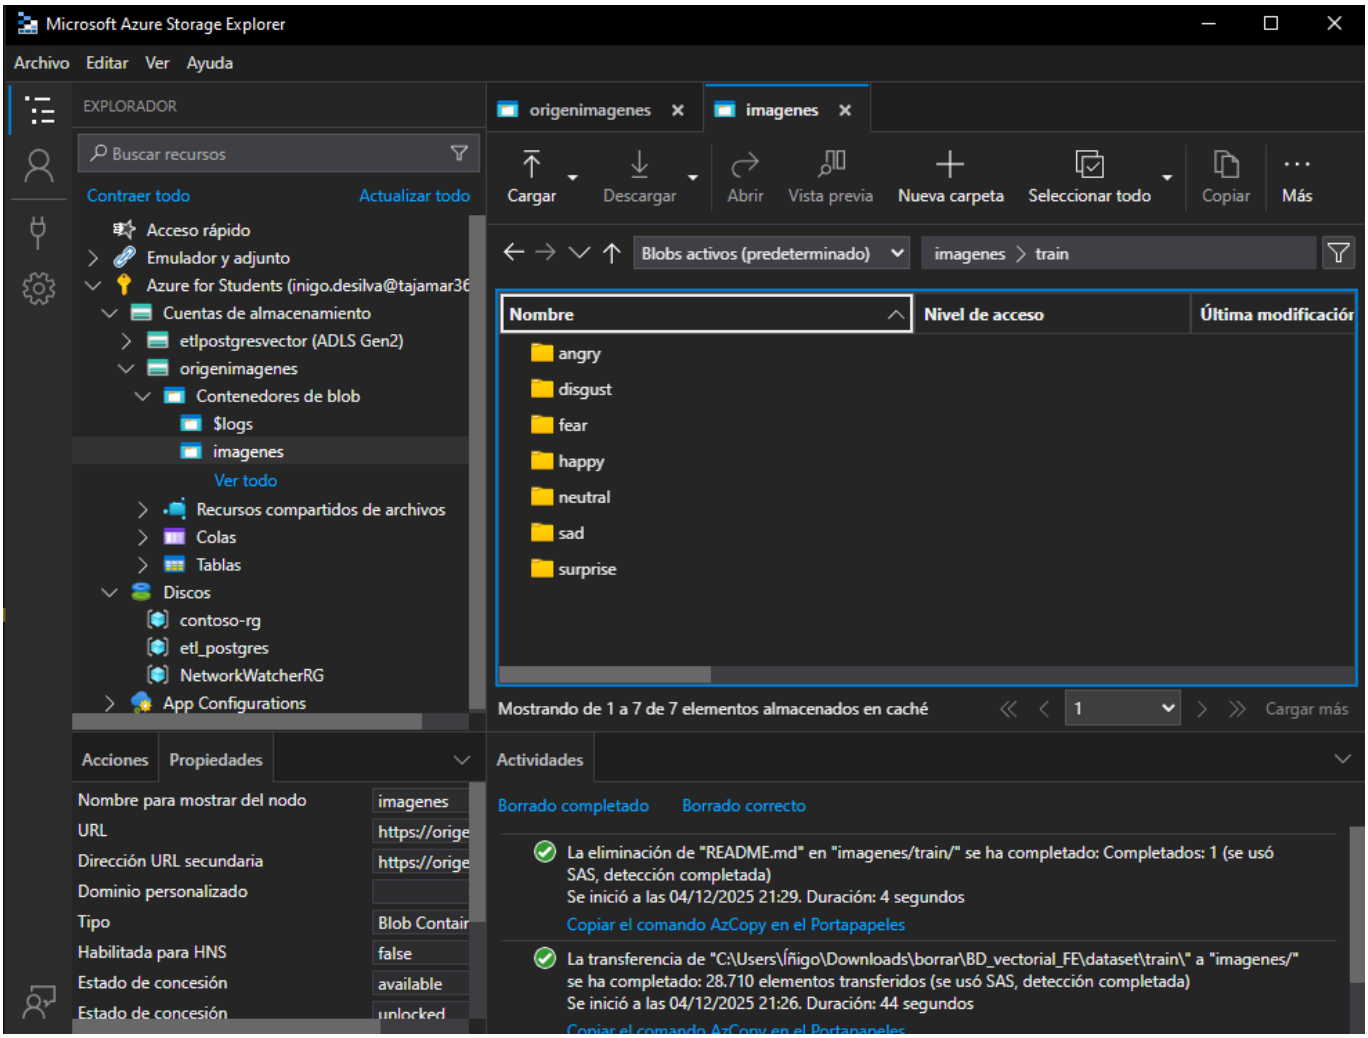

3.1. Creación del Data Lakehouse

El Data Lakehouse se implementa utilizando **Azure Data Lake Storage Gen2 (ADLS Gen2)**, que proporciona el almacenamiento escalable y las capacidades de sistema de archivos necesarias para alojar los embeddings vectoriales en formato Parquet.

1. **Creación de la Storage Account:**
    - En el Portal de Azure, se crea un recurso de **"Storage account"** .
    - Se selecciona la misma región y grupo de recursos utilizados para Azure PostgreSQL y Azure Data Factory para optimizar el rendimiento y la latencia.

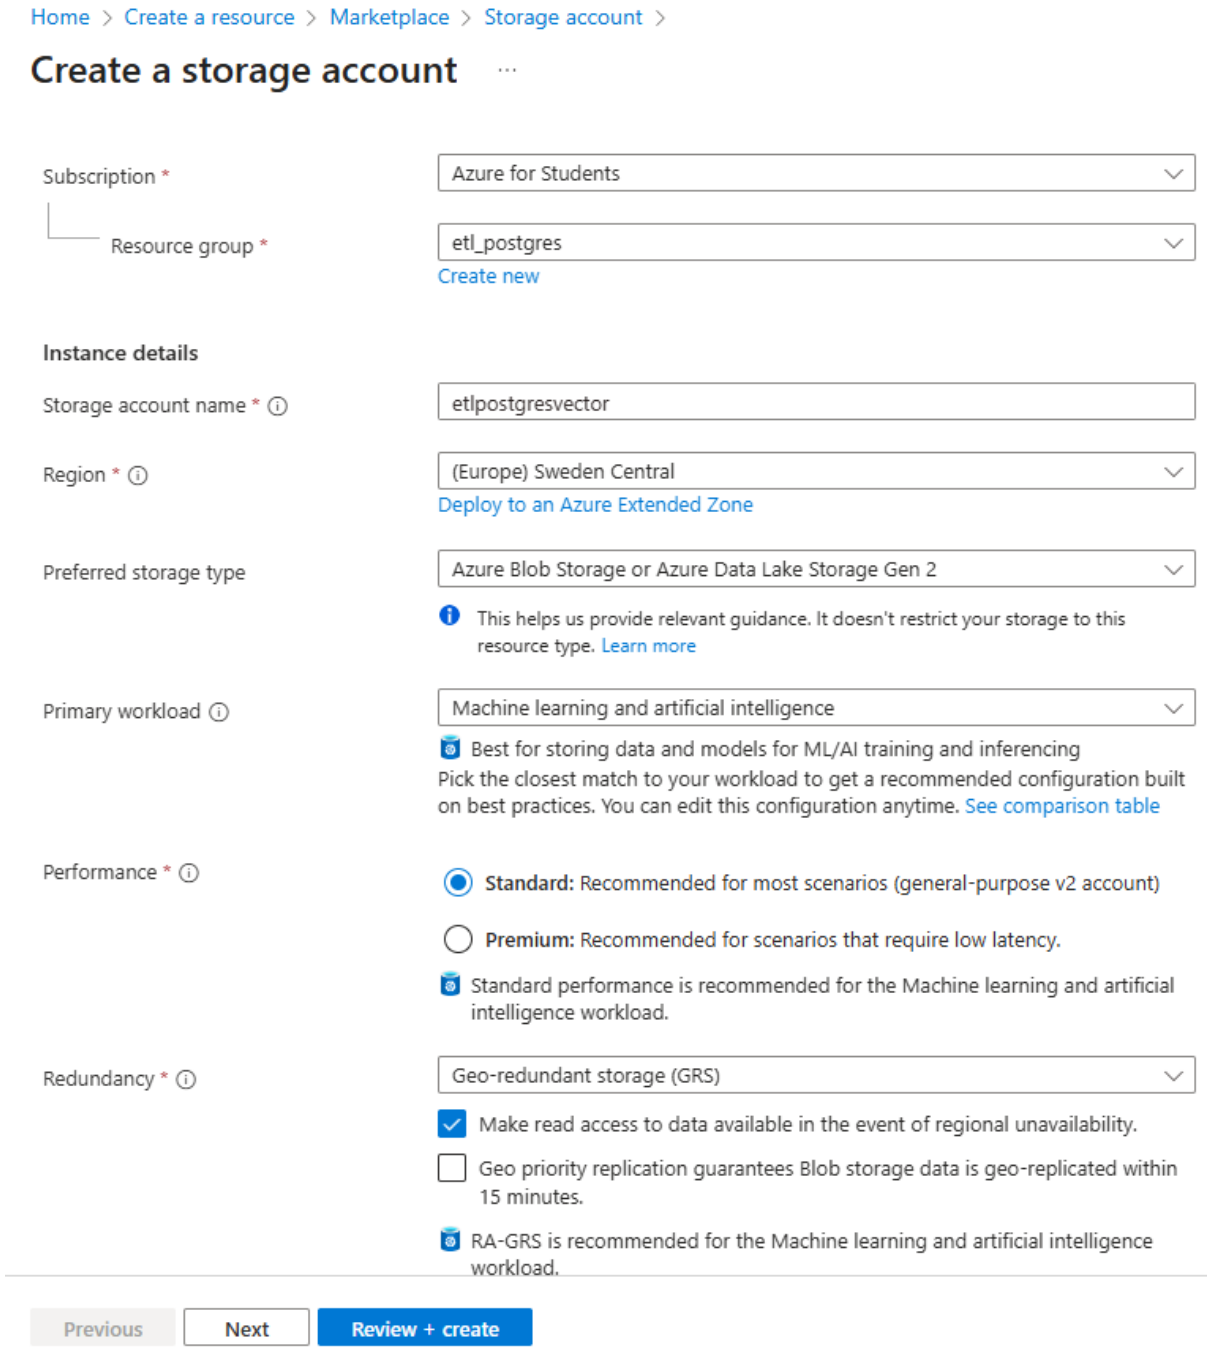

2. **Habilitación de Namespace Jerárquico (Configuración de Data Lake):**

   - **Paso Crucial:** Durante la configuración, se debe navegar a la pestaña **"Advanced"** (Opciones avanzadas).
   - En la sección **"Data Lake Storage Gen2"**, se habilita la opción **"Hierarchical namespace"** (Espacio de nombres jerárquico). Esta característica es esencial, ya que permite la gestión de directorios y archivos de manera eficiente, replicando la estructura de un sistema de archivos

tradicional, lo que define el componente Data Lakehouse.

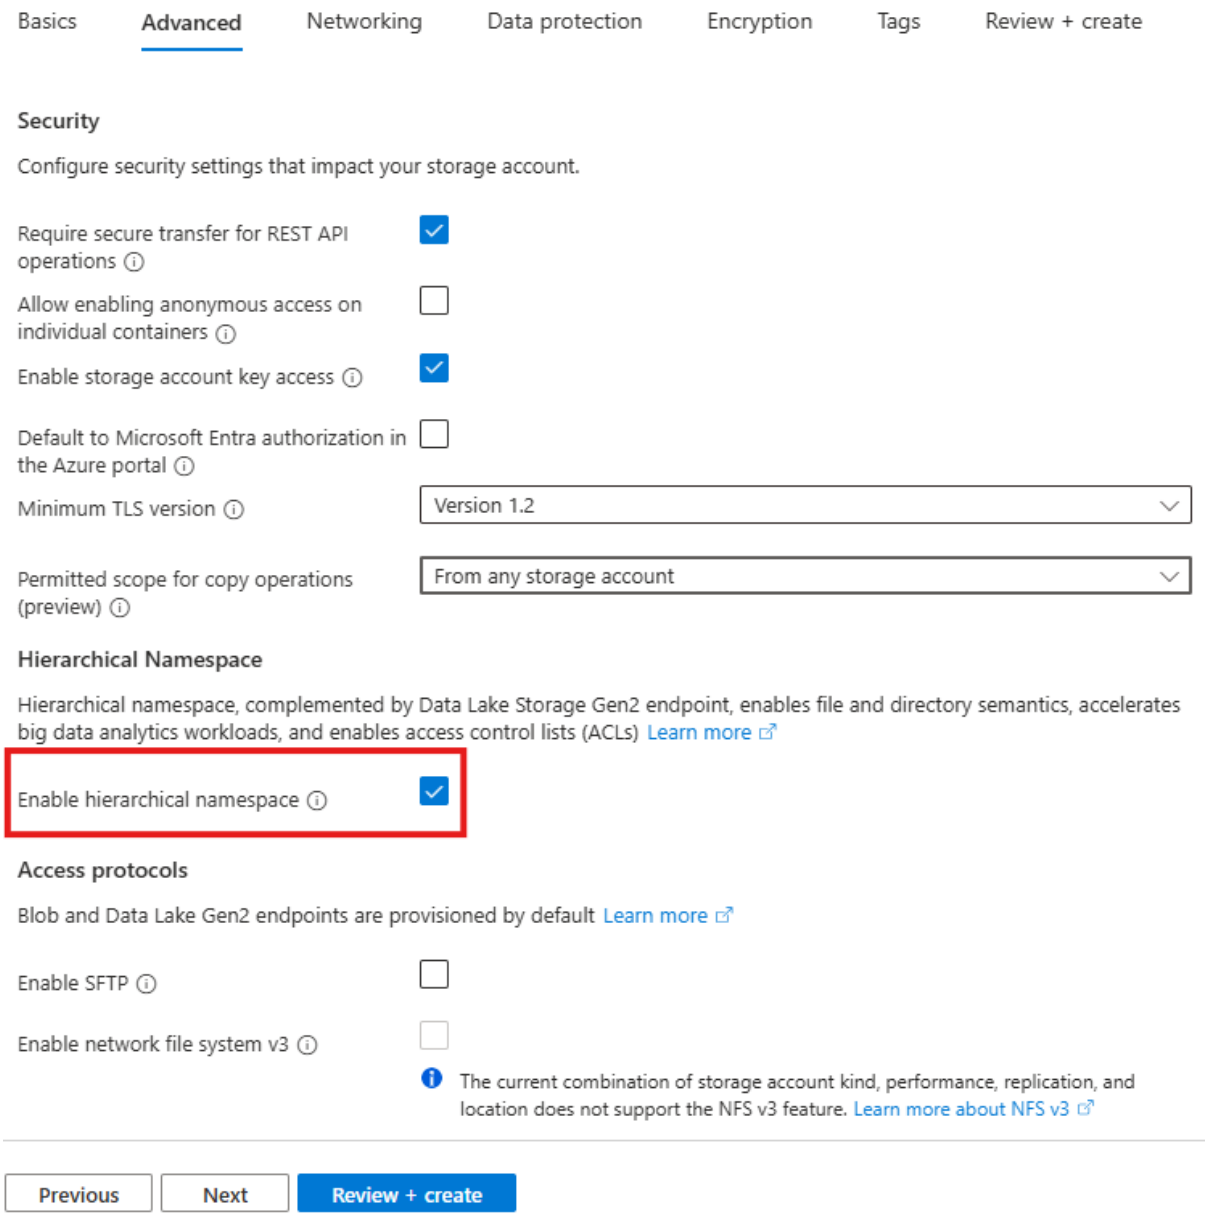

3. **Organización de Contenedores:**
    - Una vez creada la cuenta, se establece una estructura lógica dentro de un contenedor (ej., 'raw' o 'landing').
    - Azure Data Factory (ADF) cargará los archivos Parquet en esta ubicación, manteniendo la estructura de carpetas definida en el Dataset de destino (ej., 'raw/embeddings/fer2013/').

3.2. Creación del Servicio Azure Data Factory (ADF)

1. **Creación del Recurso ADF:** En el Portal de Azure, se crea un nuevo recurso de **Data Factory (V2)**. Se recomienda usar la misma región que Azure PostgreSQL y el Data Lakehouse para reducir la latencia.

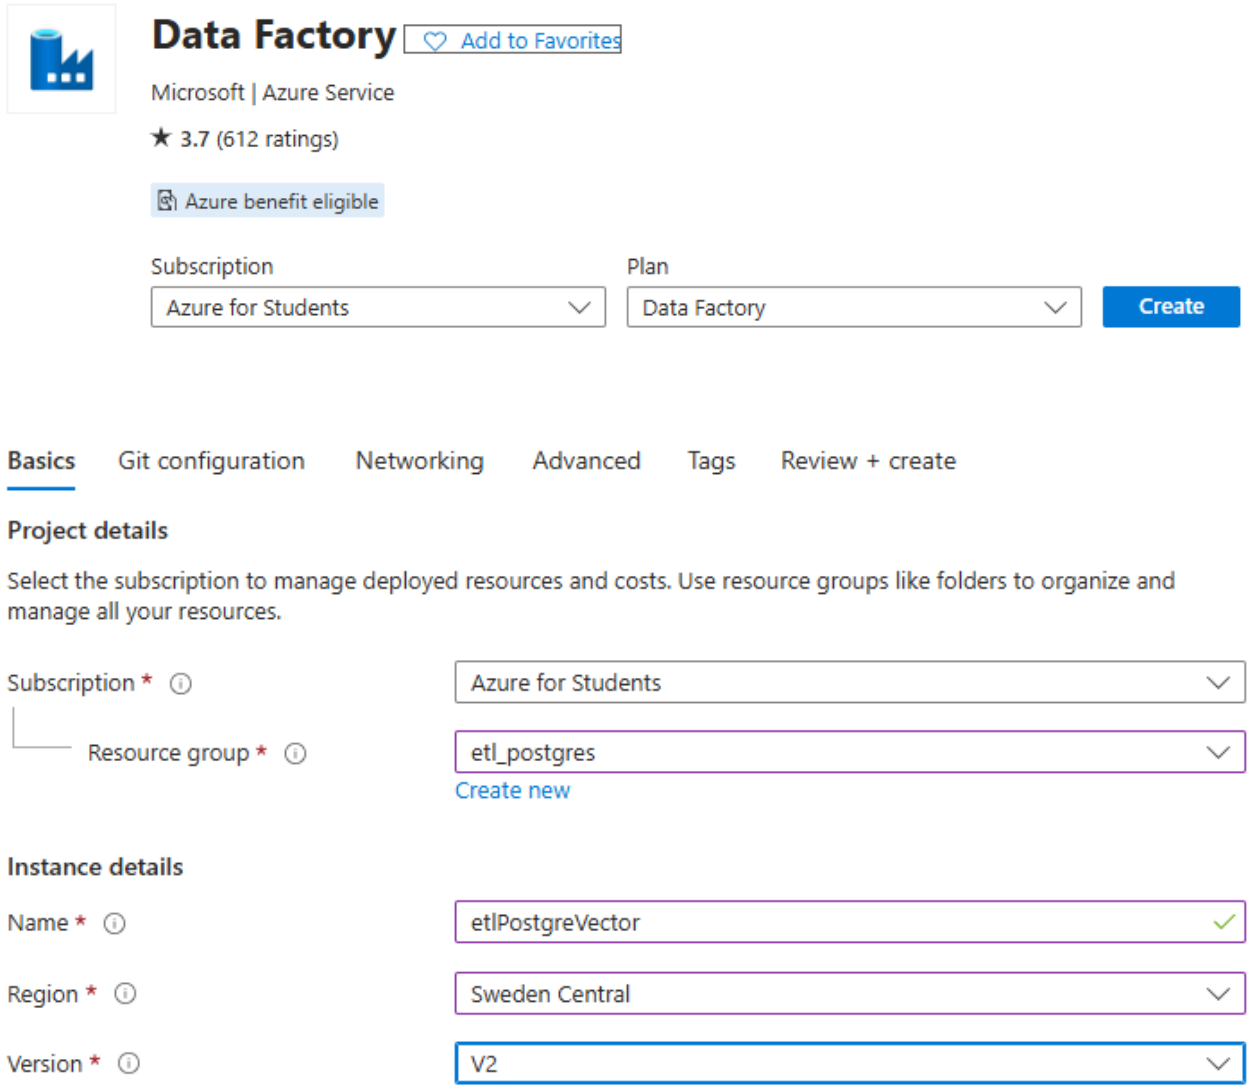

2. **Acceso al Studio:** Una vez desplegado, se accede al **Azure Data Factory Studio** para comenzar la configuración.

3.3. Configuración de Conexiones (Linked Services)

Dentro del ADF Studio, se configuran las conexiones a los almacenes de datos. Esto se realiza en la sección "Manage" (Administrar, icono del enchufe) de ADF Studio.

1. **Linked Service para Azure PostgreSQL (Origen):**
    - **Tipo:** Azure Database for PostgreSQL.
    - **Propósito:** Permite a ADF leer los datos vectoriales de la tabla 'imagenes_fer'.
    - **Configuración en ADF:**
        - Se selecciona el tipo Azure Database for PostgreSQL.
        - Se introducen los parámetros de conexión del servidor Flexible Server: Host Name, Database name (ej., 'fer_vct'), User name (<AZURE_ADMIN>), y Password, tal como se configuraron en el Paso 2.
        - Es obligatorio realizar una prueba de conexión (Test connection) antes de crear el servicio.

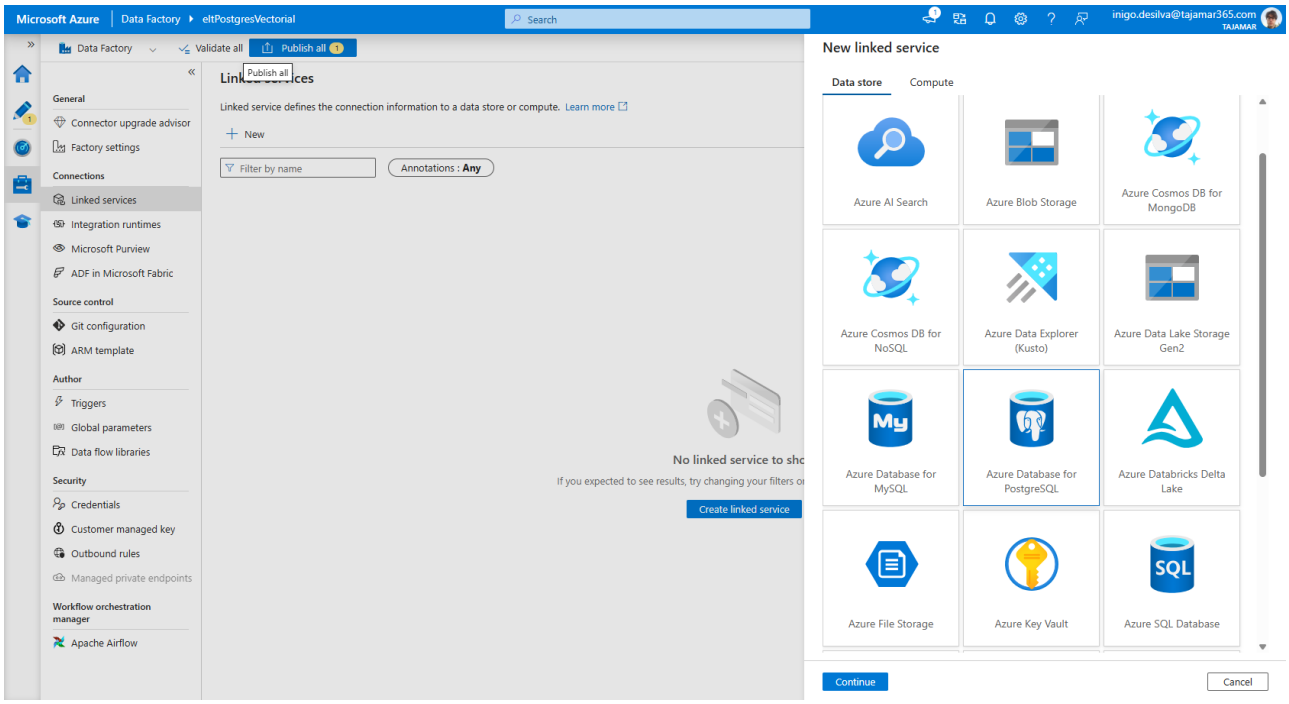
Microsoft Azure
Data Factory
eltPostgresVectorial
Search
inigo.desilva@tajamar365.com
TAJAMAR
Data Factory
Validate all
Publish all
Publish all
General
Connector upgrade advisor
Factory settings
Connections
Linked services
Integration runtimes
Microsoft Purview
ADF in Microsoft Fabric
Source control
Git configuration
ARM template
Author
Triggers
Global parameters
Data flow libraries
Security
Credentials
Customer managed key
Outbound rules
Managed private endpoints
Workflow orchestration manager
Apache Airflow
Linked services
Linked service defines the connection information to a data store or compute. Learn more
New
Filter by name
Annotations : Any
No linked service to sho
If you expected to see results, try changing your filters or
Create linked service
New linked service
Data store
Compute
Azure AI Search
Azure Blob Storage
Azure Cosmos DB for MongoDB
Azure Cosmos DB for NoSQL
Azure Data Explorer (Kusto)
Azure Data Lake Storage Gen2
Azure Database for MySQL
Azure Database for PostgreSQL
Azure Databricks Delta Lake
Azure File Storage
Azure Key Vault
Azure SQL Database
Continue
Cancel

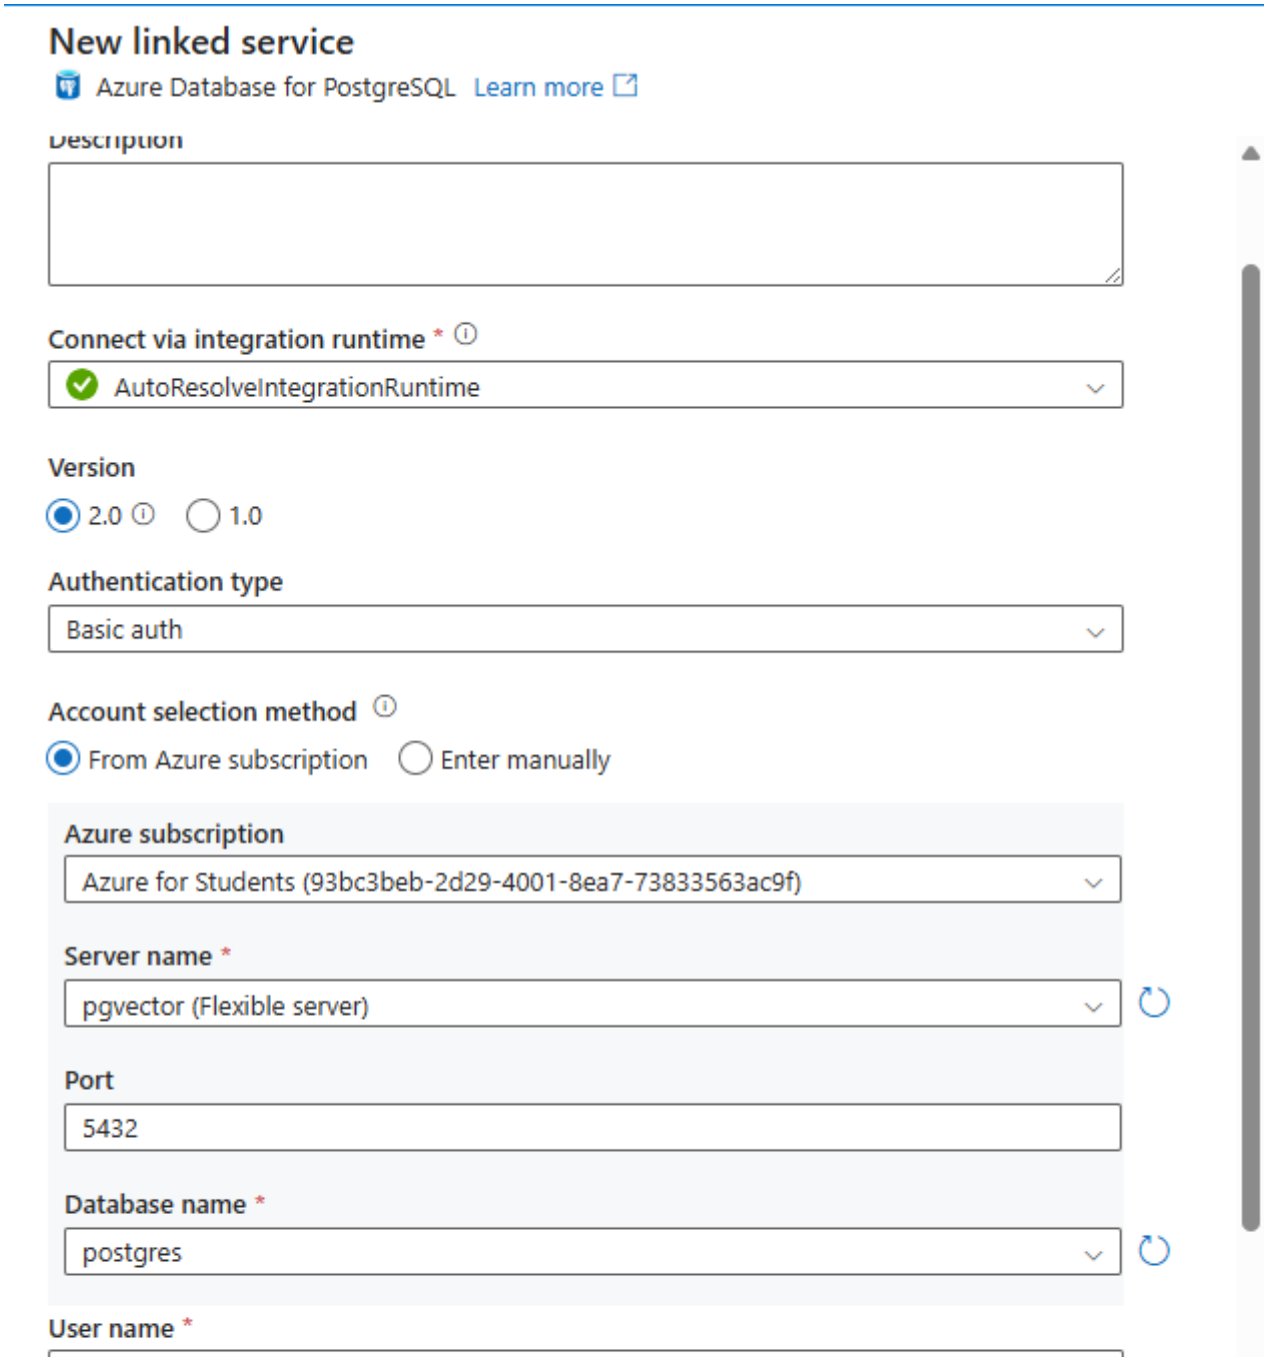
New linked service
Azure Database for PostgreSQL Learn more
Description
Connect via integration runtime *
AutoResolveIntegrationRuntime
Version
2.0
1.0
Authentication type
Basic auth
Account selection method
From Azure subscription
Enter manually
Azure subscription
Azure for Students (93bc3beb-2d29-4001-8ea7-73833563ac9f)
Server name *
pgvector (Flexible server)
Port
5432
Database name *
postgres
User name *

2. **Linked Service para Data Lakehouse (Destino):**
    - **Tipo:** Azure Data Lake Storage Gen2 (ADLS Gen2).
    - **Propósito:** Permite a ADF escribir los archivos Parquet resultantes en el Data Lake.
    - **Configuración en ADF:**
        - Se selecciona el tipo Azure Data Lake Storage Gen2.
        - Se elige la Cuenta de Almacenamiento (Storage account name) correspondiente a tu Data Lakehouse.
        - Se recomienda usar la Identidad Administrada (Managed Identity) para la autenticación por motivos de seguridad.
        - Se verifica la conexión y se crea el servicio.

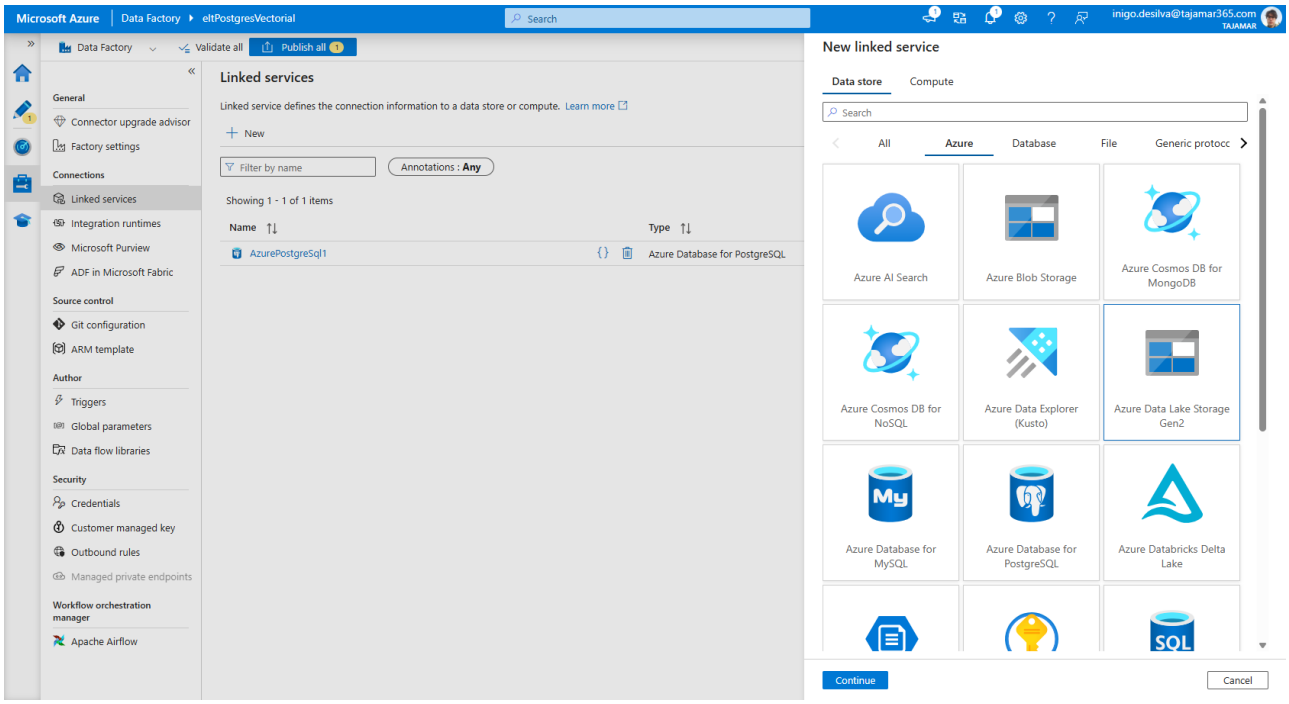
Microsoft Azure
Data Factory
eltPostgresVectorial
Search
inigo.desilva@tajamar365.com
TAJAMAR
Data Factory
Validate all
Publish all
Linked services
Linked service defines the connection information to a data store or compute. Learn more
New
Filter by name
Annotations : Any
Showing 1 - 1 of 1 items
Name
Type
AzurePostgreSql1
Azure Database for PostgreSQL
General
Connector upgrade advisor
Factory settings
Connections
Linked services
Integration runtimes
Microsoft Purview
ADF in Microsoft Fabric
Source control
Git configuration
ARM template
Author
Triggers
Global parameters
Data flow libraries
Security
Credentials
Customer managed key
Outbound rules
Managed private endpoints
Workflow orchestration manager
Apache Airflow
New linked service
Data store
Compute
Search
All
Azure
Database
File
Generic protocc
Azure AI Search
Azure Blob Storage
Azure Cosmos DB for MongoDB
Azure Cosmos DB for NoSQL
Azure Data Explorer (Kusto)
Azure Data Lake Storage Gen2
Azure Database for MySQL
Azure Database for PostgreSQL
Azure Databricks Delta Lake
Continue
Cancel

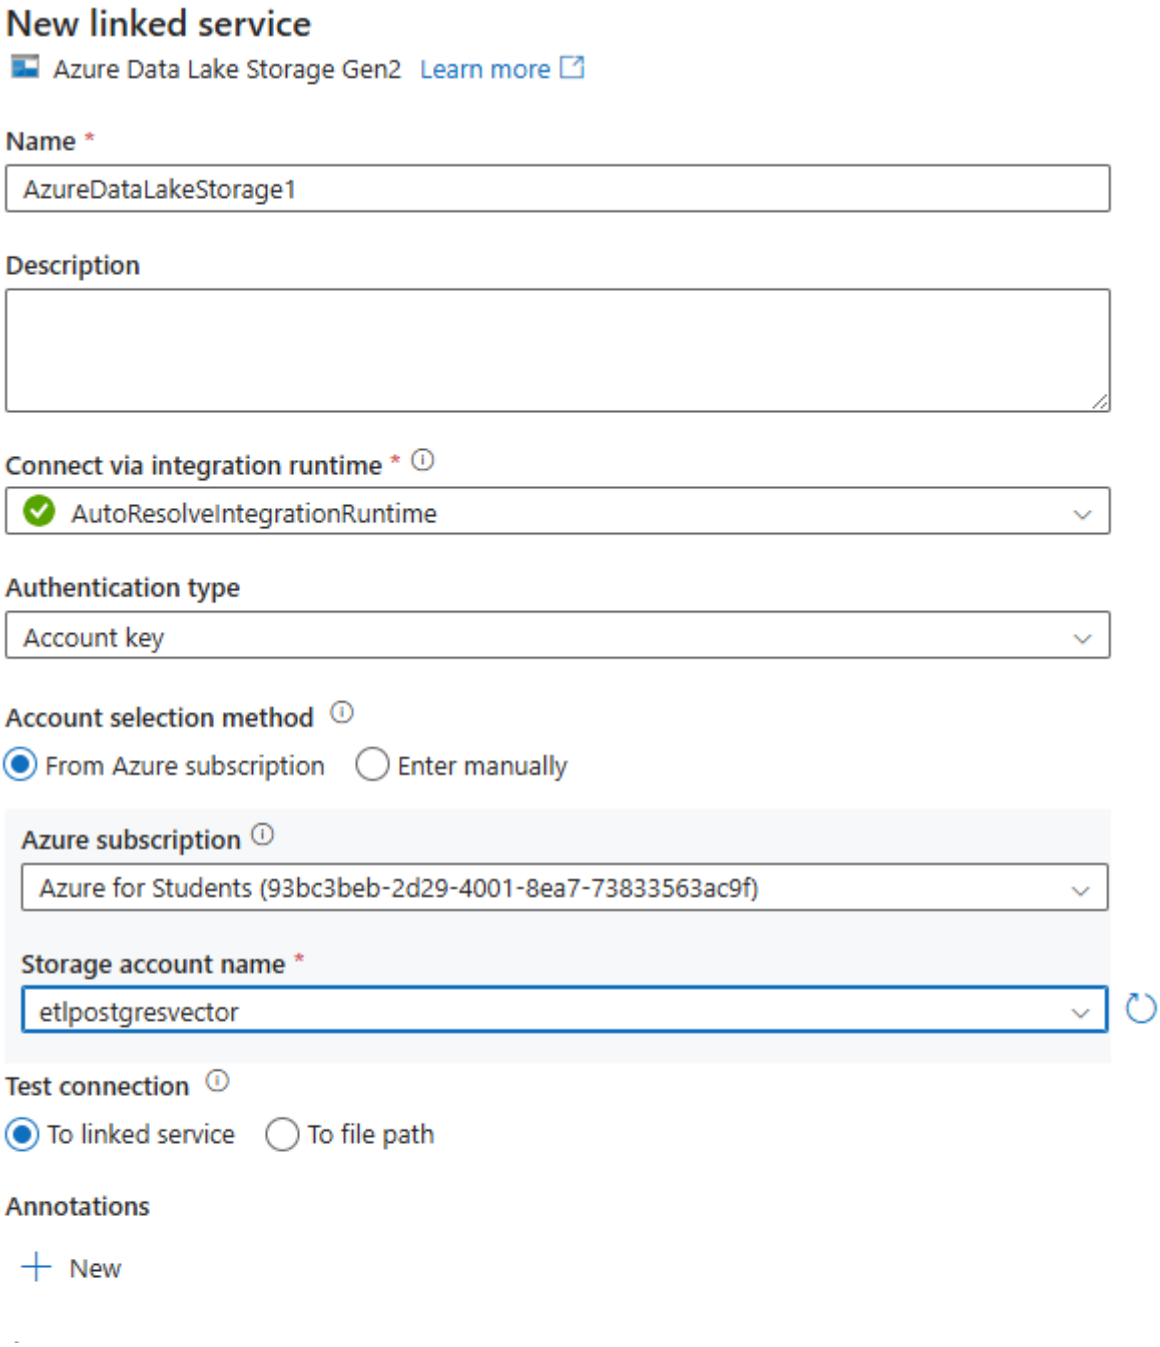
New linked service
Azure Data Lake Storage Gen2 Learn more
Name *
AzureDataLakeStorage1
Description
Connect via integration runtime *
AutoResolveIntegrationRuntime
Authentication type
Account key
Account selection method
From Azure subscription
Enter manually
Azure subscription
Azure for Students (93bc3beb-2d29-4001-8ea7-73833563ac9f)
Storage account name *
etlpostgresvector
Test connection
To linked service
To file path
Annotations
New

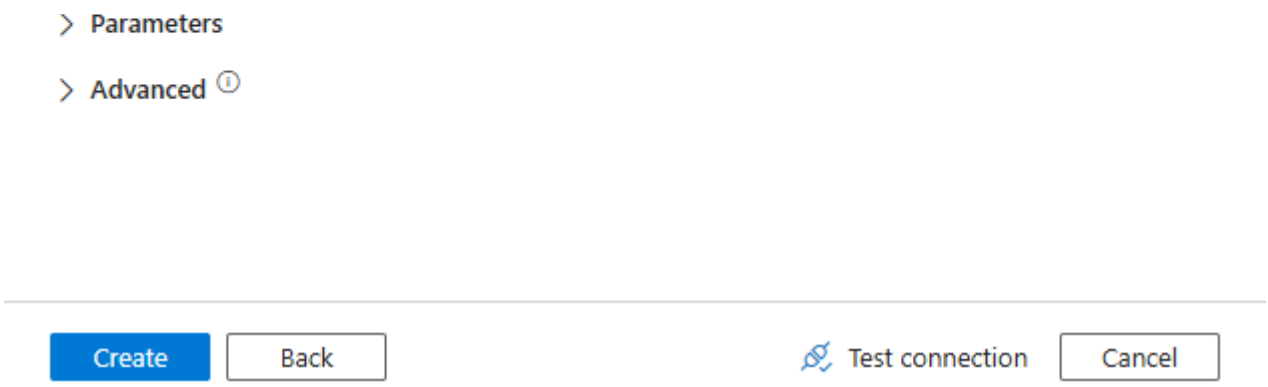

3. **Linked Service para Azure Blob Storage (Origen Imágenes - Cloud):**
    - **Tipo:** Azure Blob Storage.
    - **Propósito:** Es la fuente de los archivos binarios de imagen una vez cargados a la nube, eliminando el uso del SHIR.
    - **Configuración en ADF:**
        - Se selecciona el tipo Azure Blob Storage.
        - Se elige la Cuenta de Almacenamiento donde se cargaron las imágenes.
        - **Integration Runtime:** Se selecciona el **AutoResolveIntegrationRuntime** (o el predeterminado) para una conexión directa en la nube.
        - La conexión se realiza directamente en la nube.

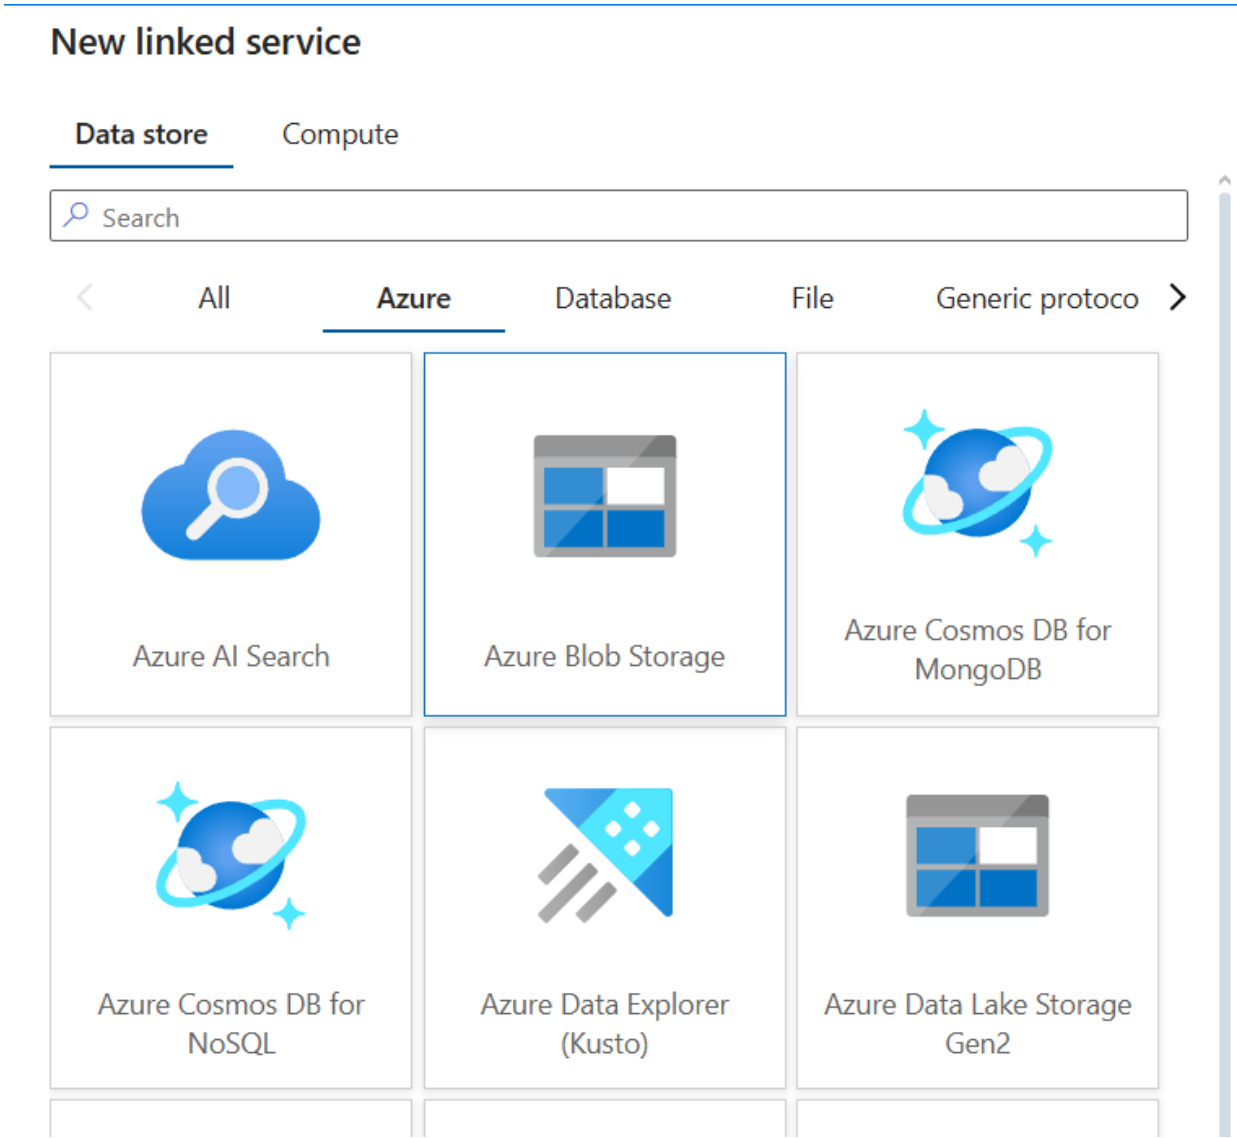

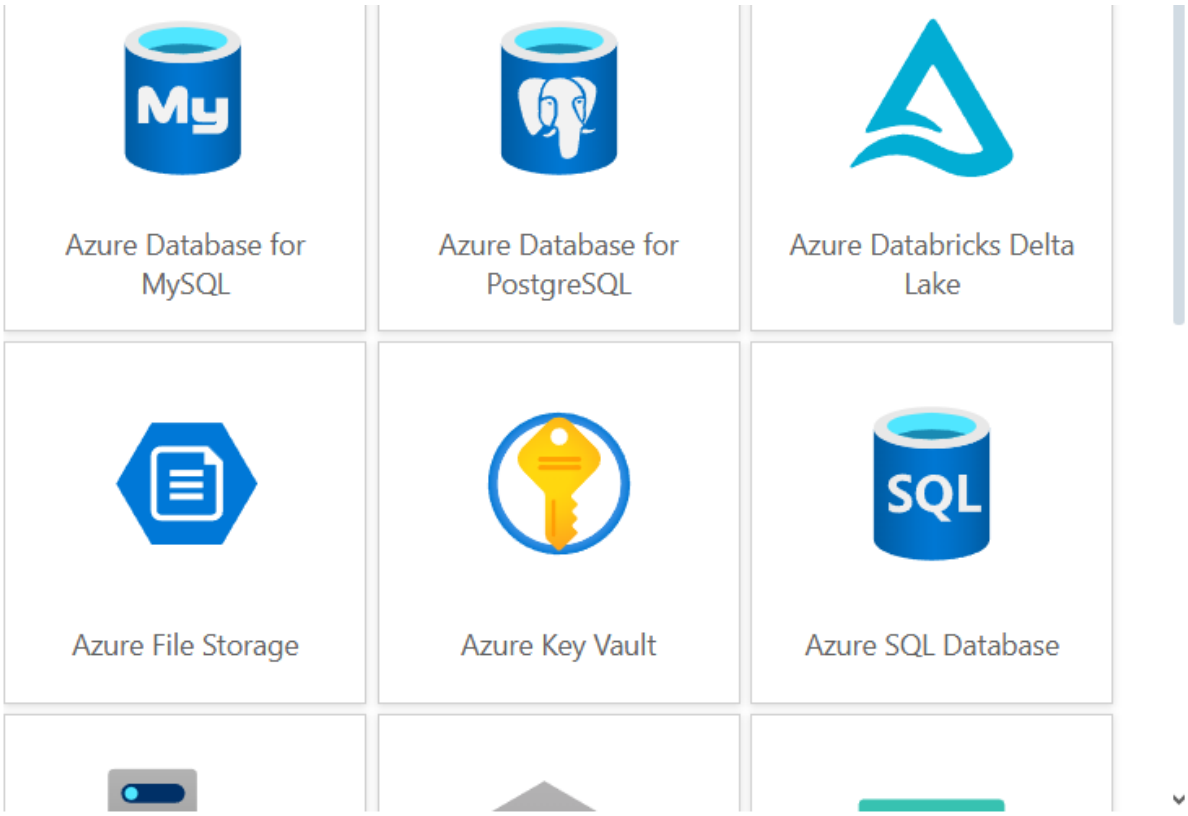

Continue Cancel

New linked service

Azure Blob Storage Learn more

Name *

AzureBlobStorage1

Description

Connect via integration runtime *

AutoResolveIntegrationRuntime

Authentication type

Account key

Connection string | Azure Key Vault

Account selection method

From Azure subscription | Enter manually

Azure subscription

Azure for Students (93bc3beb-2d29-4001-8ea7-73833563ac9f)

Storage account name *

origenimagenes

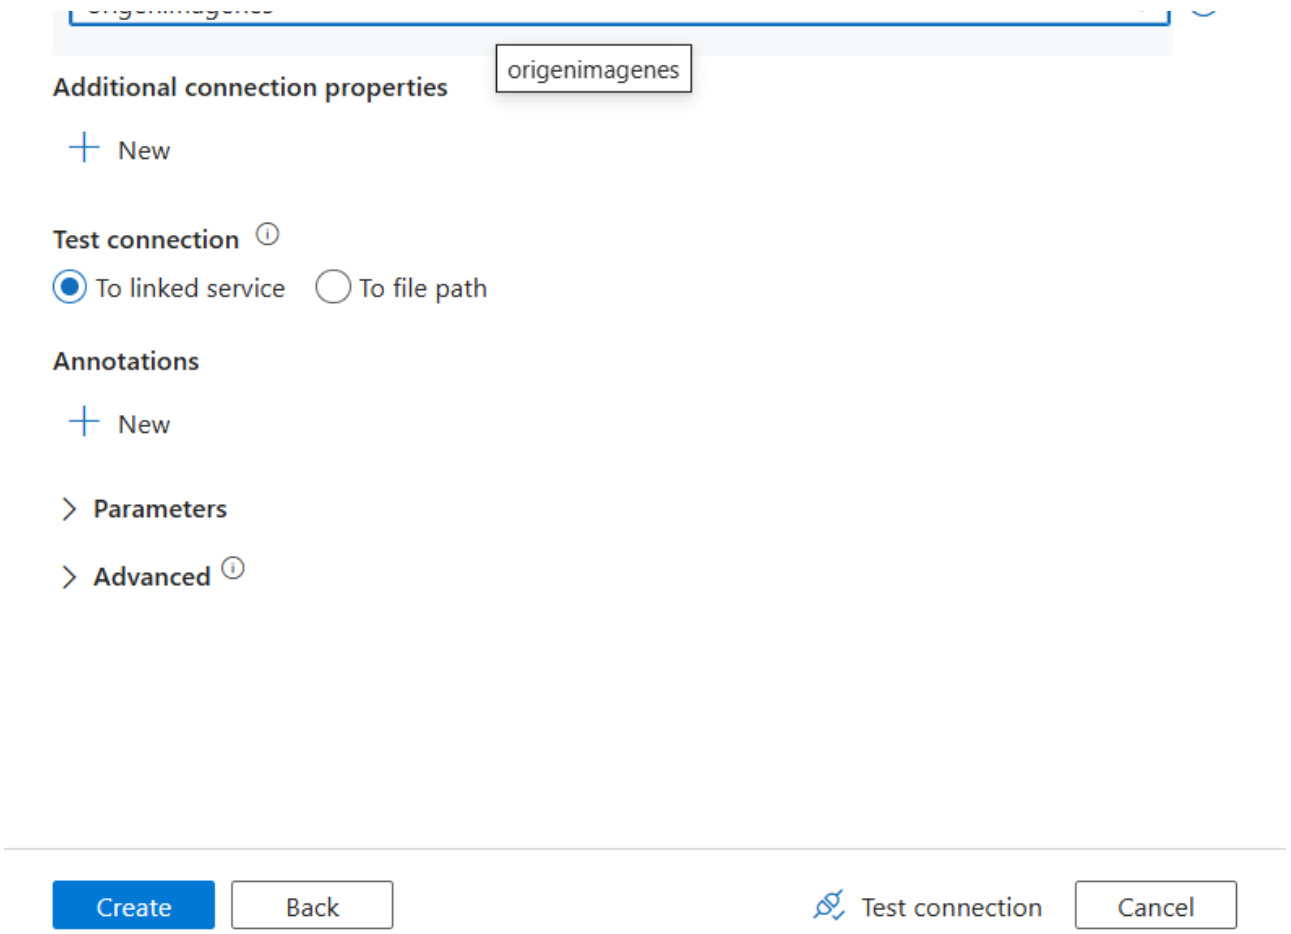

3.4. Definición de Datasets

Los Datasets apuntan a los datos específicos dentro de las conexiones definidas. Para manejar los dos flujos de datos (embeddings desde la nube y binarios desde local) se requieren cuatro Datasets.

La configuración de estos Datasets se realiza dentro del Azure Data Factory Studio en la sección "Author" (Autor).

1. **Dataset de Origen (DS_PgVector_ImagenesFer):**
    - **Propósito:** Apunta a la tabla 'imagenes_fer' en Azure PostgreSQL (para extraer los embeddings).
    - **Configuración en ADF:**
        - Tipo: Azure Database for PostgreSQL.
        - Linked Service: Se enlaza al servicio de PostgreSQL configurado en 3.2.1.

- Tabla: Se selecciona la tabla 'imagenes_fer'.

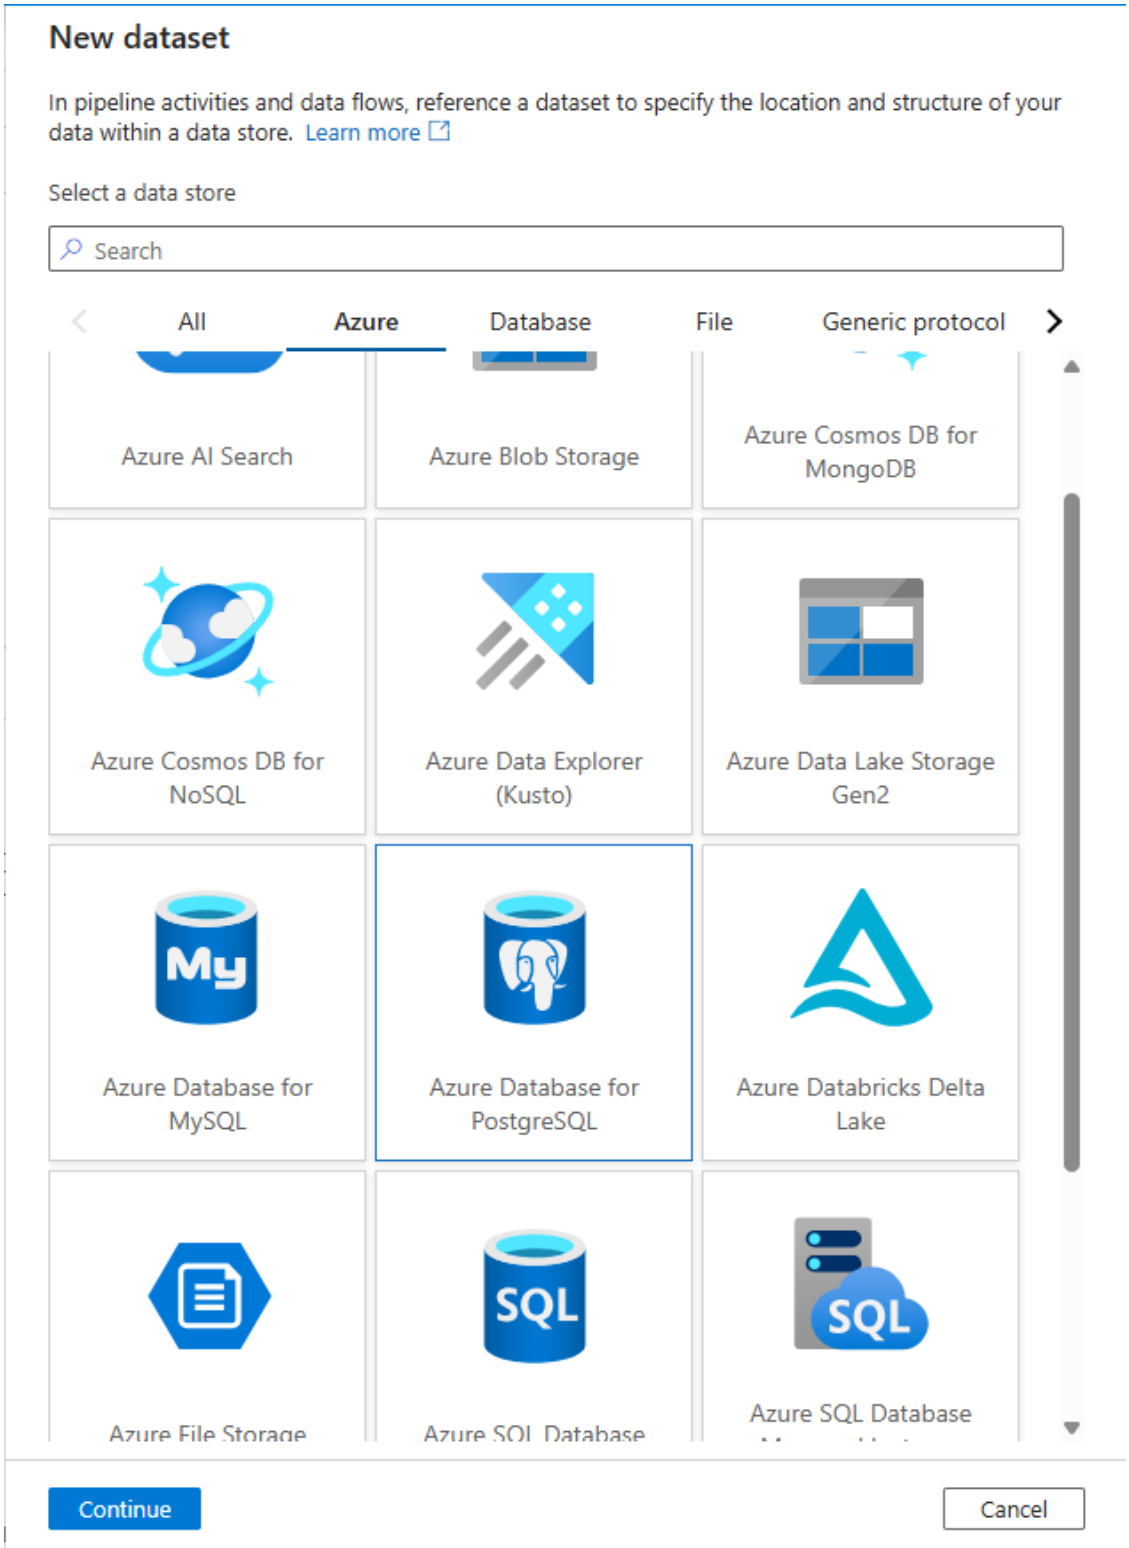

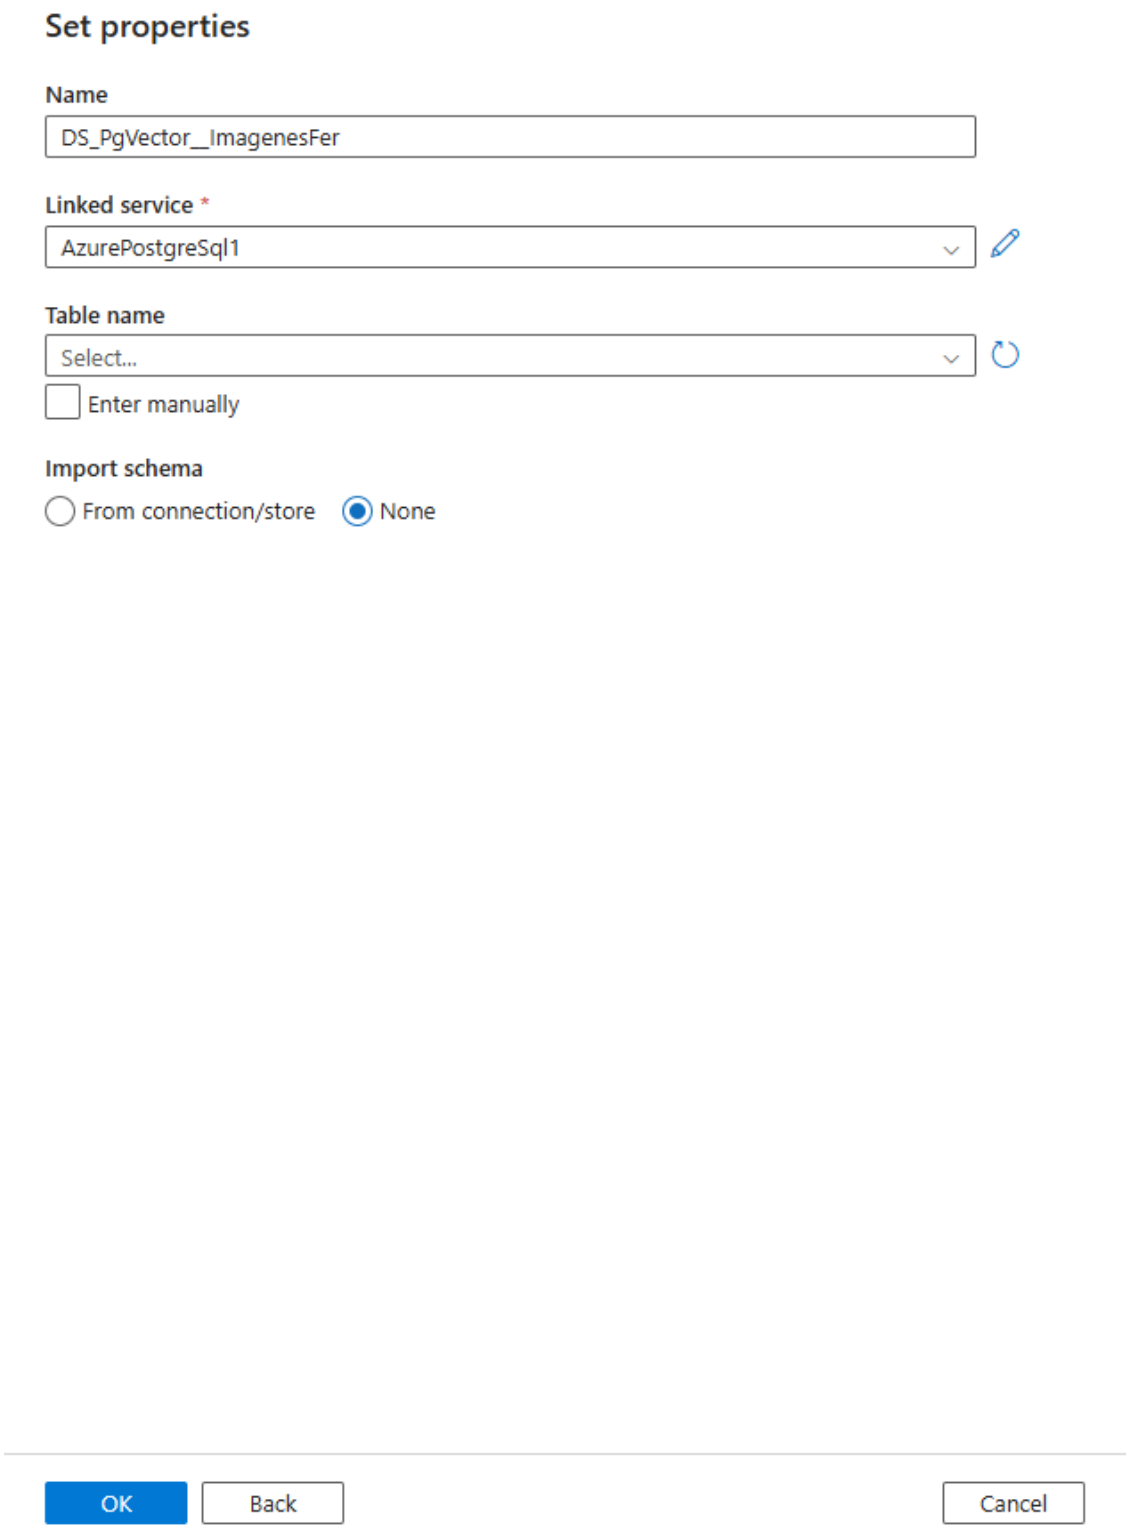

2. **Dataset de Destino (DS_Lakehouse_Embeddings):**
    - **Propósito:** Define la ubicación y el formato para los embeddings en el Data Lakehouse.
    - **Configuración en ADF:**
        - Tipo: Azure Data Lake Storage Gen2.
        - Formato: Se selecciona **Parquet** por ser columnar y optimizado para análisis.
        - Linked Service: Se enlaza al servicio de ADLS Gen2 configurado en 3.2.2.

- Ruta de Archivo: Se especifica la ruta lógica (ej., 'raw/embeddings/fer2013/').

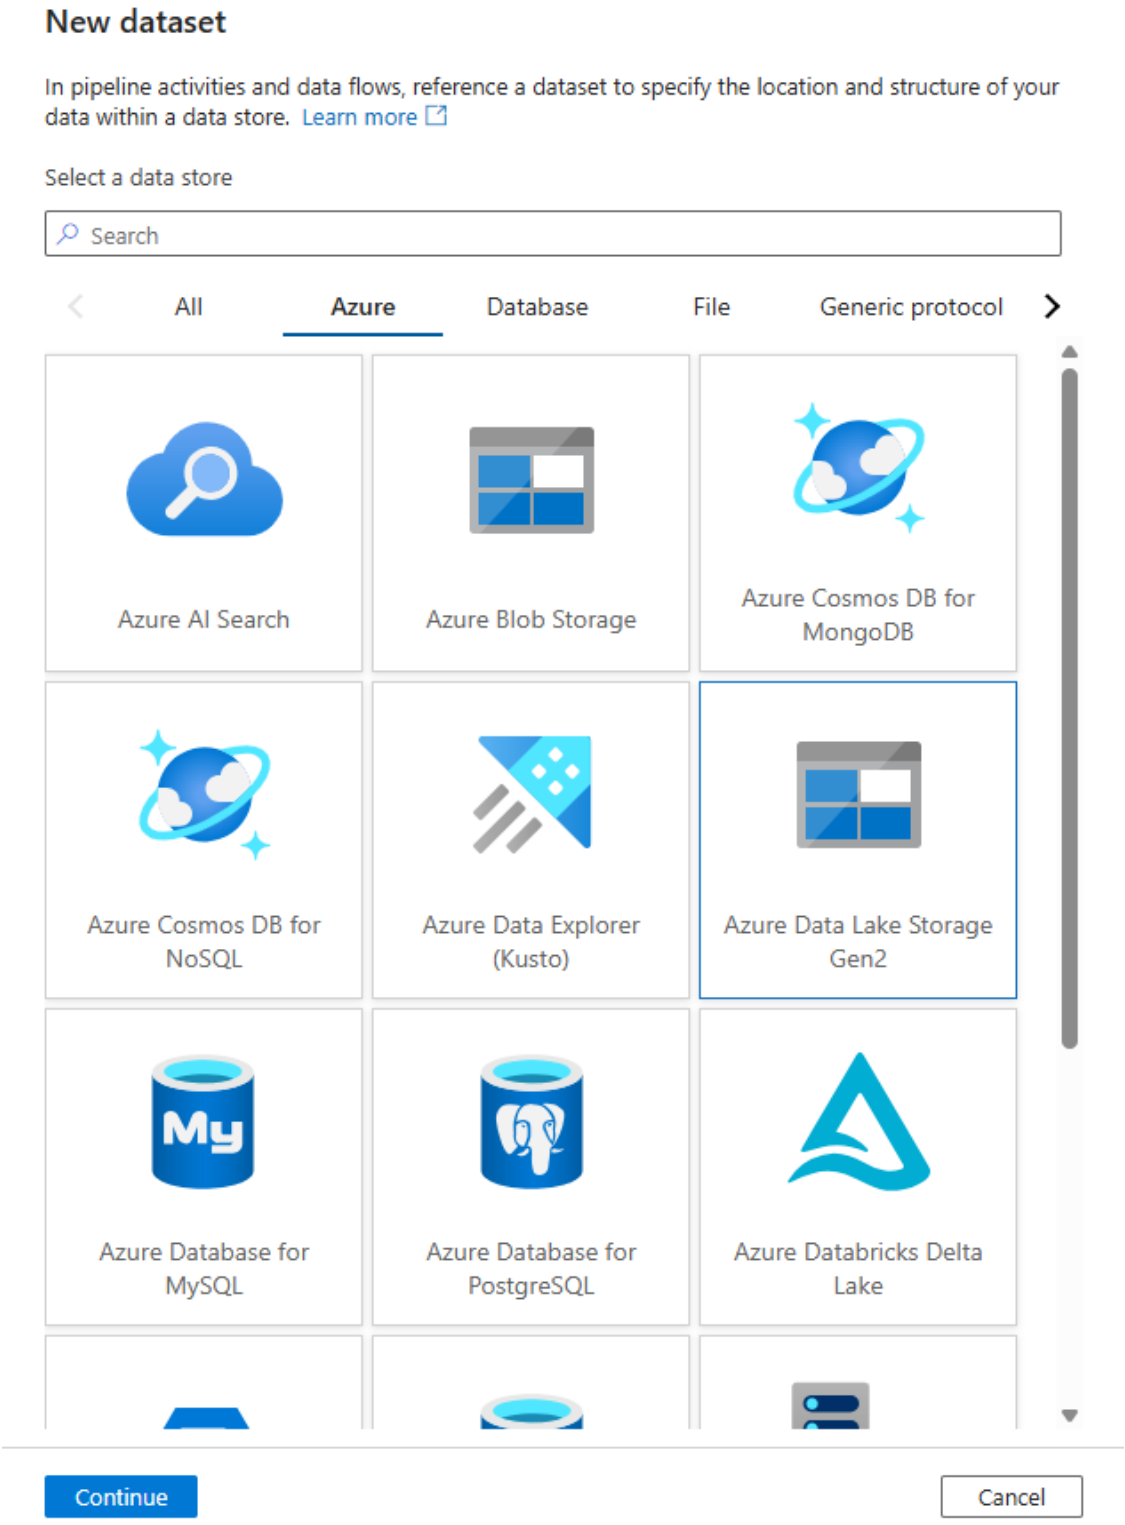

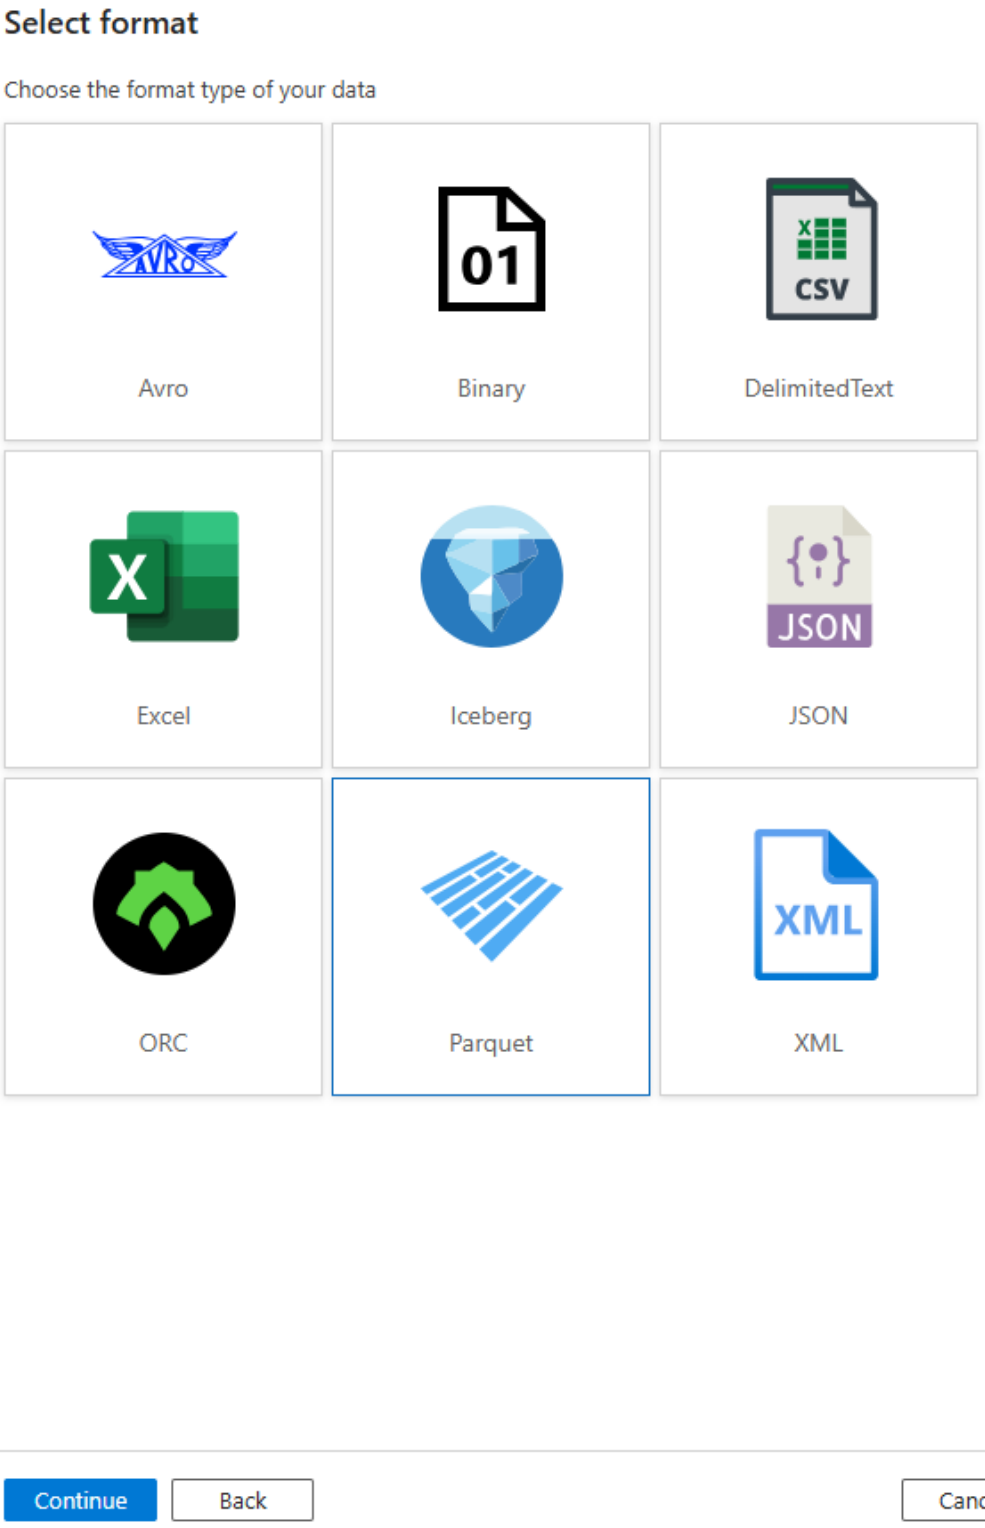
Select format
Choose the format type of your data
Avro
Binary
DelimitedText
Excel
Iceberg
JSON
ORC
Parquet
XML
Continue
Back
Cancel

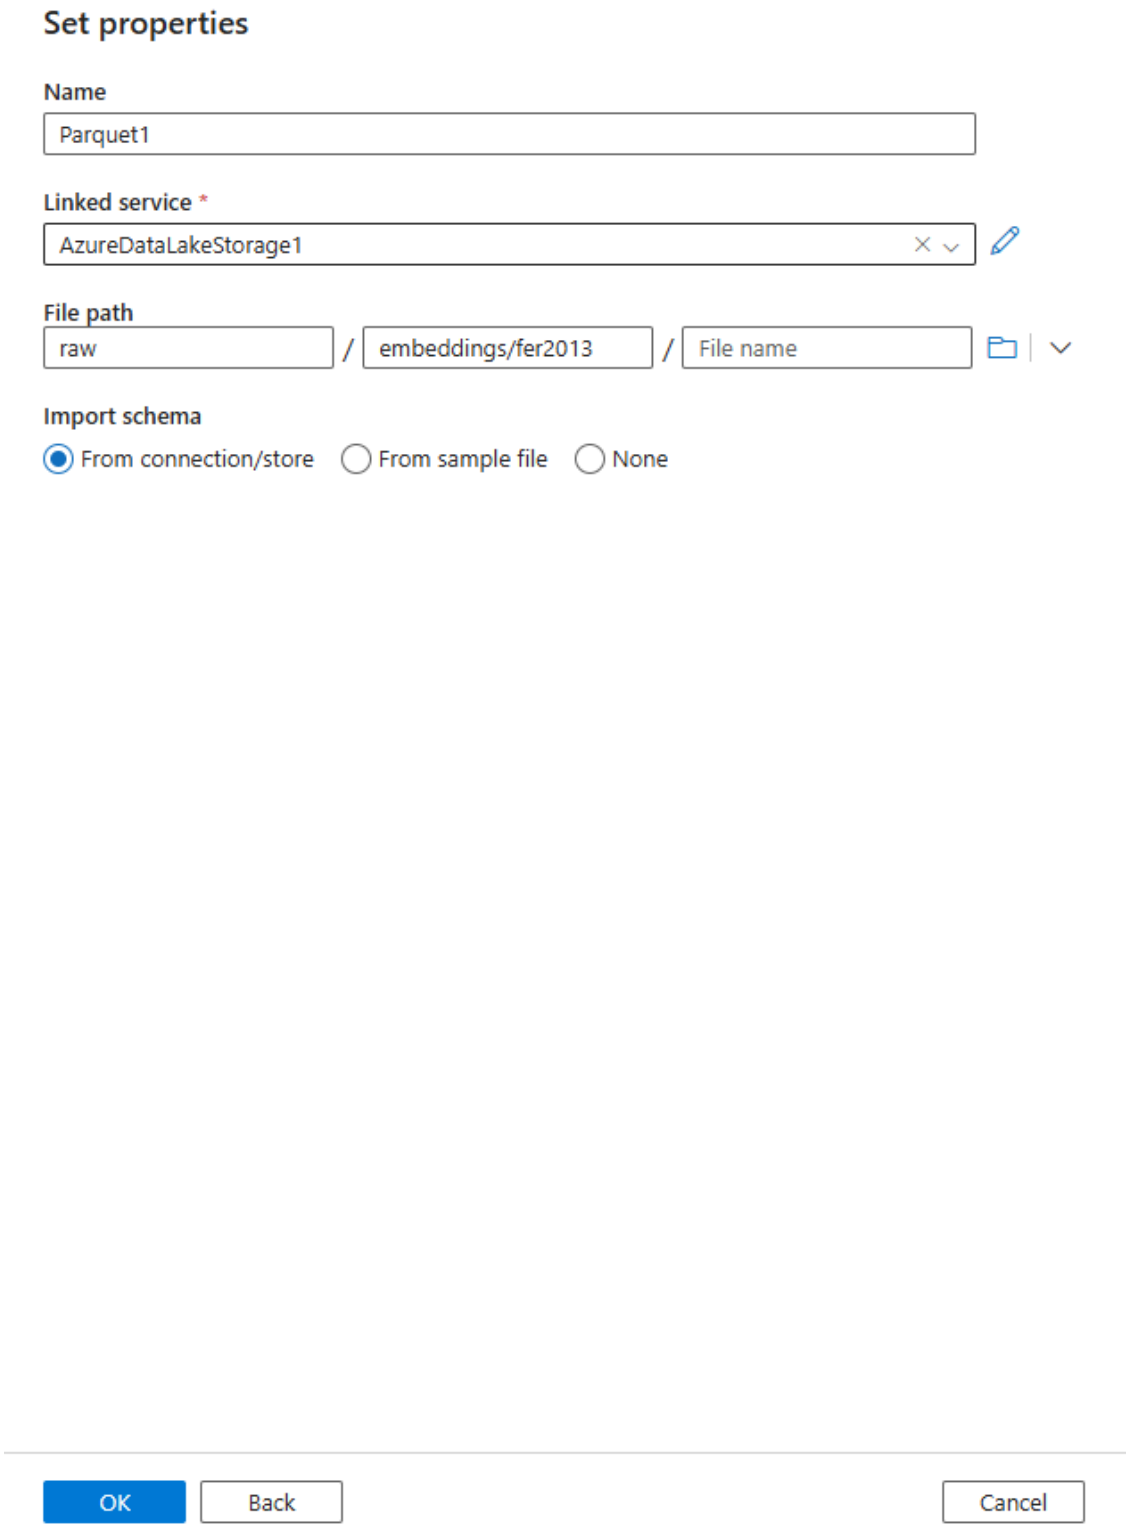

3. **Dataset de Origen Binario (DS_Images_Source):**
    - **Propósito:** Apunta a la ubicación de los archivos PNG del dataset FER2013 en **Azure Blob Storage**, asumiendo que ya han sido cargados.
    - **Configuración en ADF:**
        - Tipo: **Azure Blob Storage**.
        - Linked Service: Se enlaza al nuevo Linked Service de **Azure Blob Storage** configurado en 3.2.3.
        - Formato: Se selecciona **Binary** (Binario) para tratar los archivos sin modificar su contenido.

- Ruta: Se indica la subcarpeta dentro del contenedor de Blob Storage donde se encuentran las imágenes (ej., 'train').

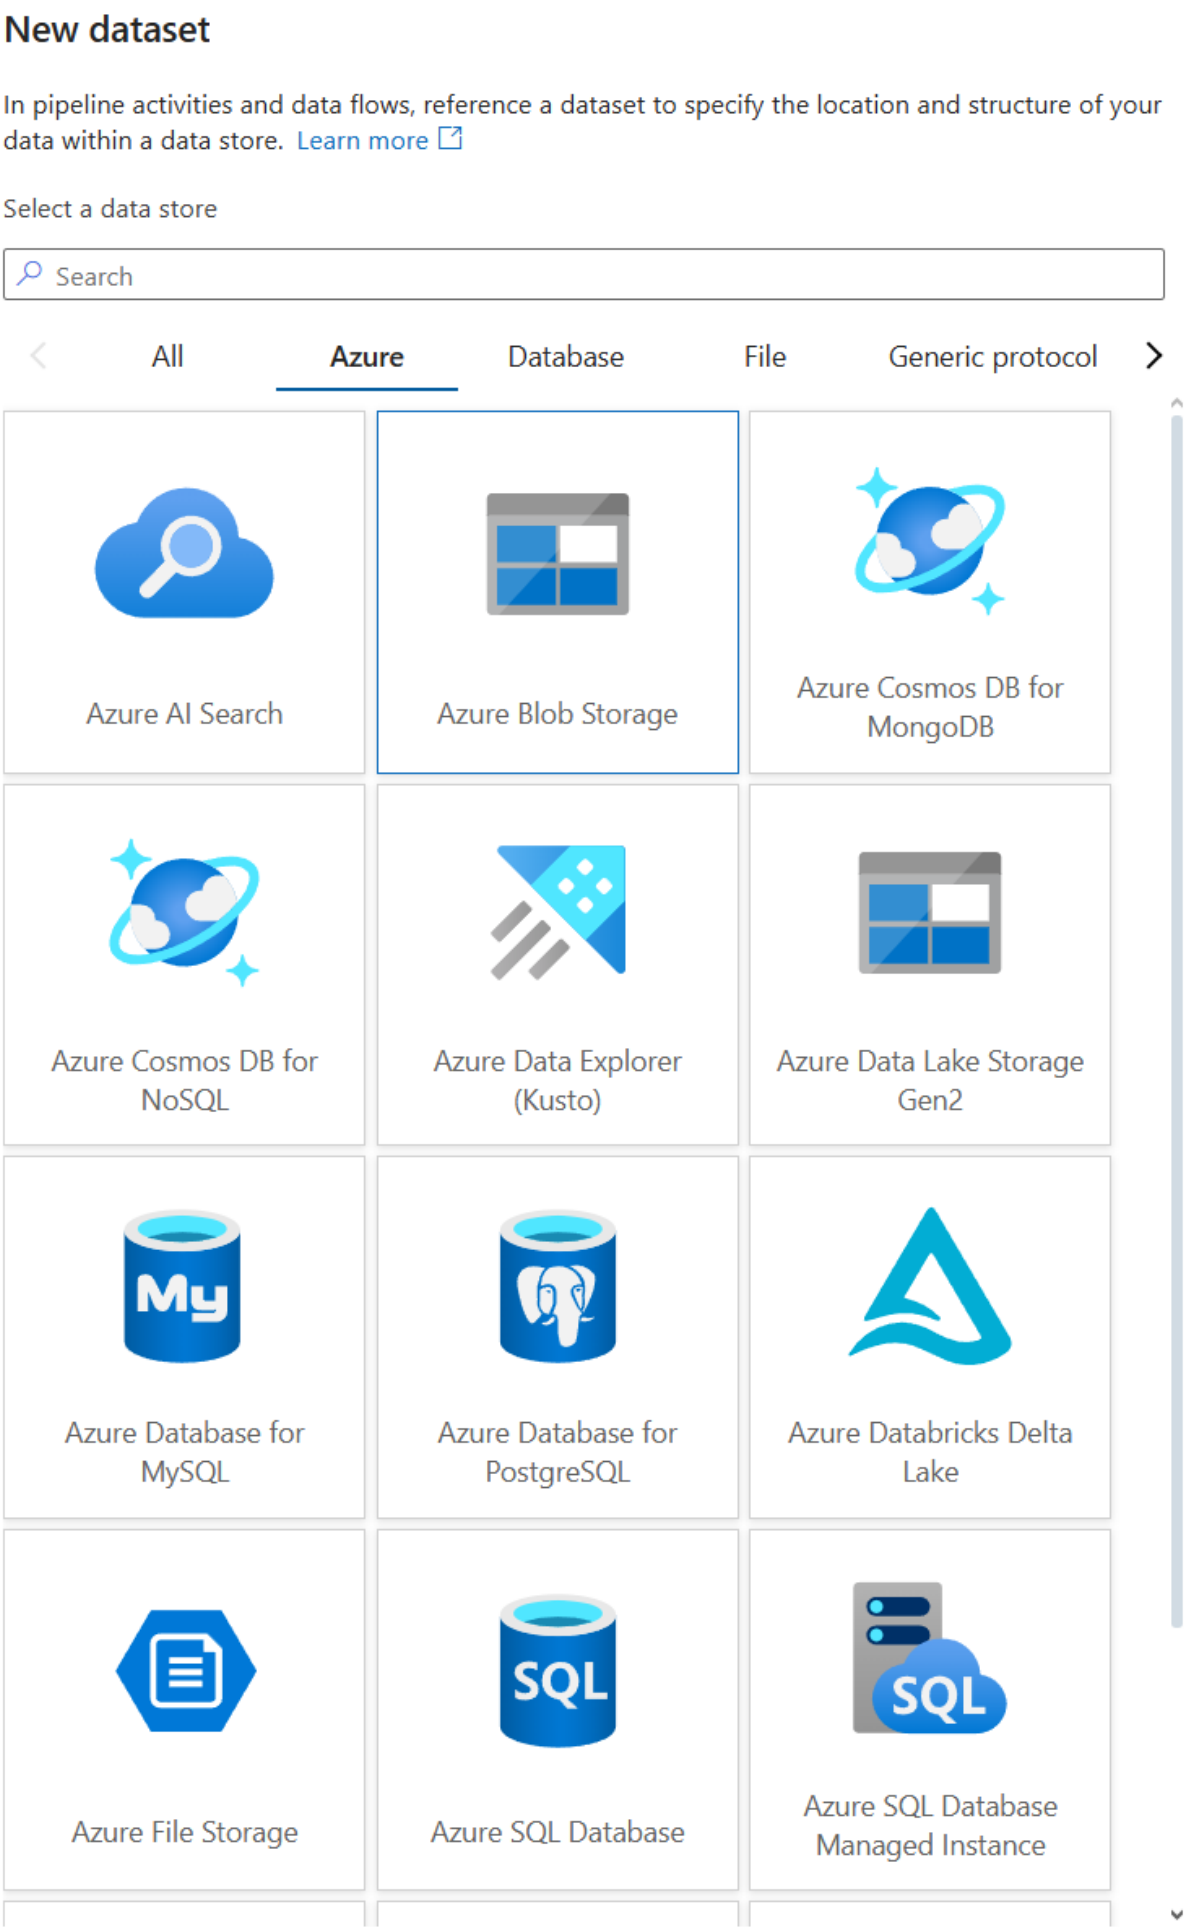

Continue Cancel

Select format

Choose the format type of your data

Avro

Binary

DelimitedText

Excel

JSON

ORC

Parquet

XML

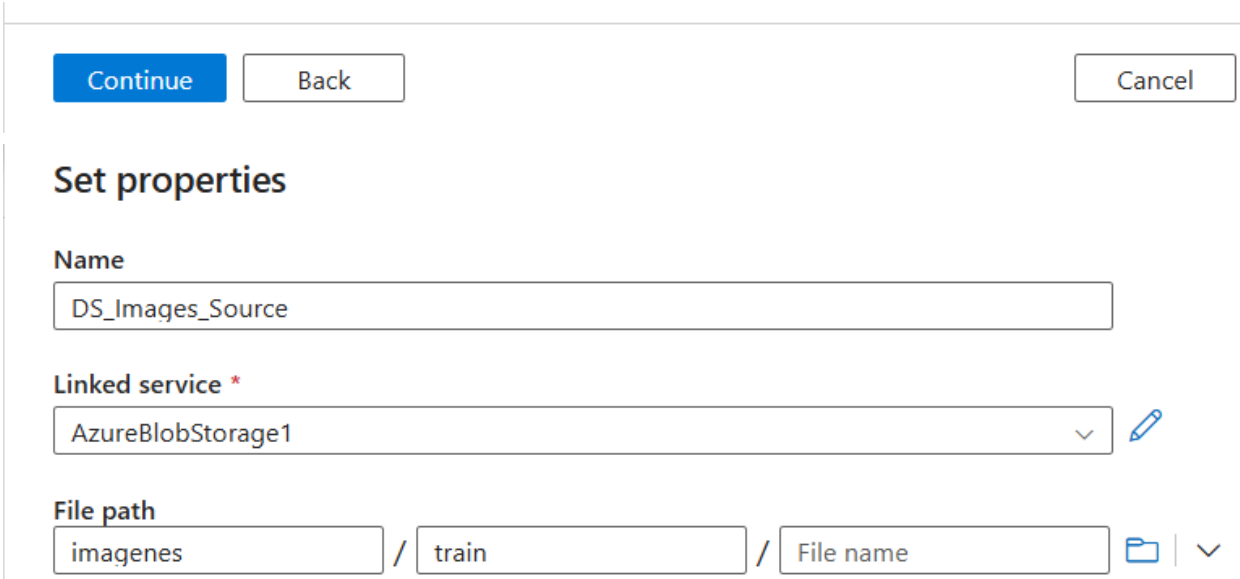
Continue
Back
Cancel
Set properties
Name
DS_Images_Source
Linked service *
AzureBlobStorage1
File path
imagenes
/
train
/
File name

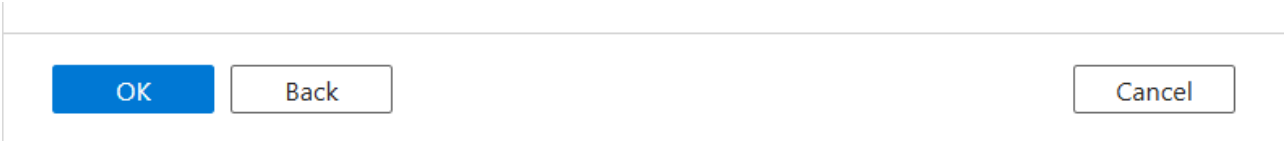

4. **Dataset de Destino Binario (DS_Lakehouse_Images):**
    - **Propósito:** Define la ubicación para las imágenes originales sin alteración en el Data Lakehouse.
    - **Configuración en ADF:**
        - Tipo: Azure Data Lake Storage Gen2.
        - Formato: Se selecciona **Binary** (Binario).
        - Linked Service: Se enlaza al servicio de ADLS Gen2.
        - Ruta de Archivo: Se especifica una ruta para las imágenes (ej., 'raw/images/fer2013/') separada de los embeddings.

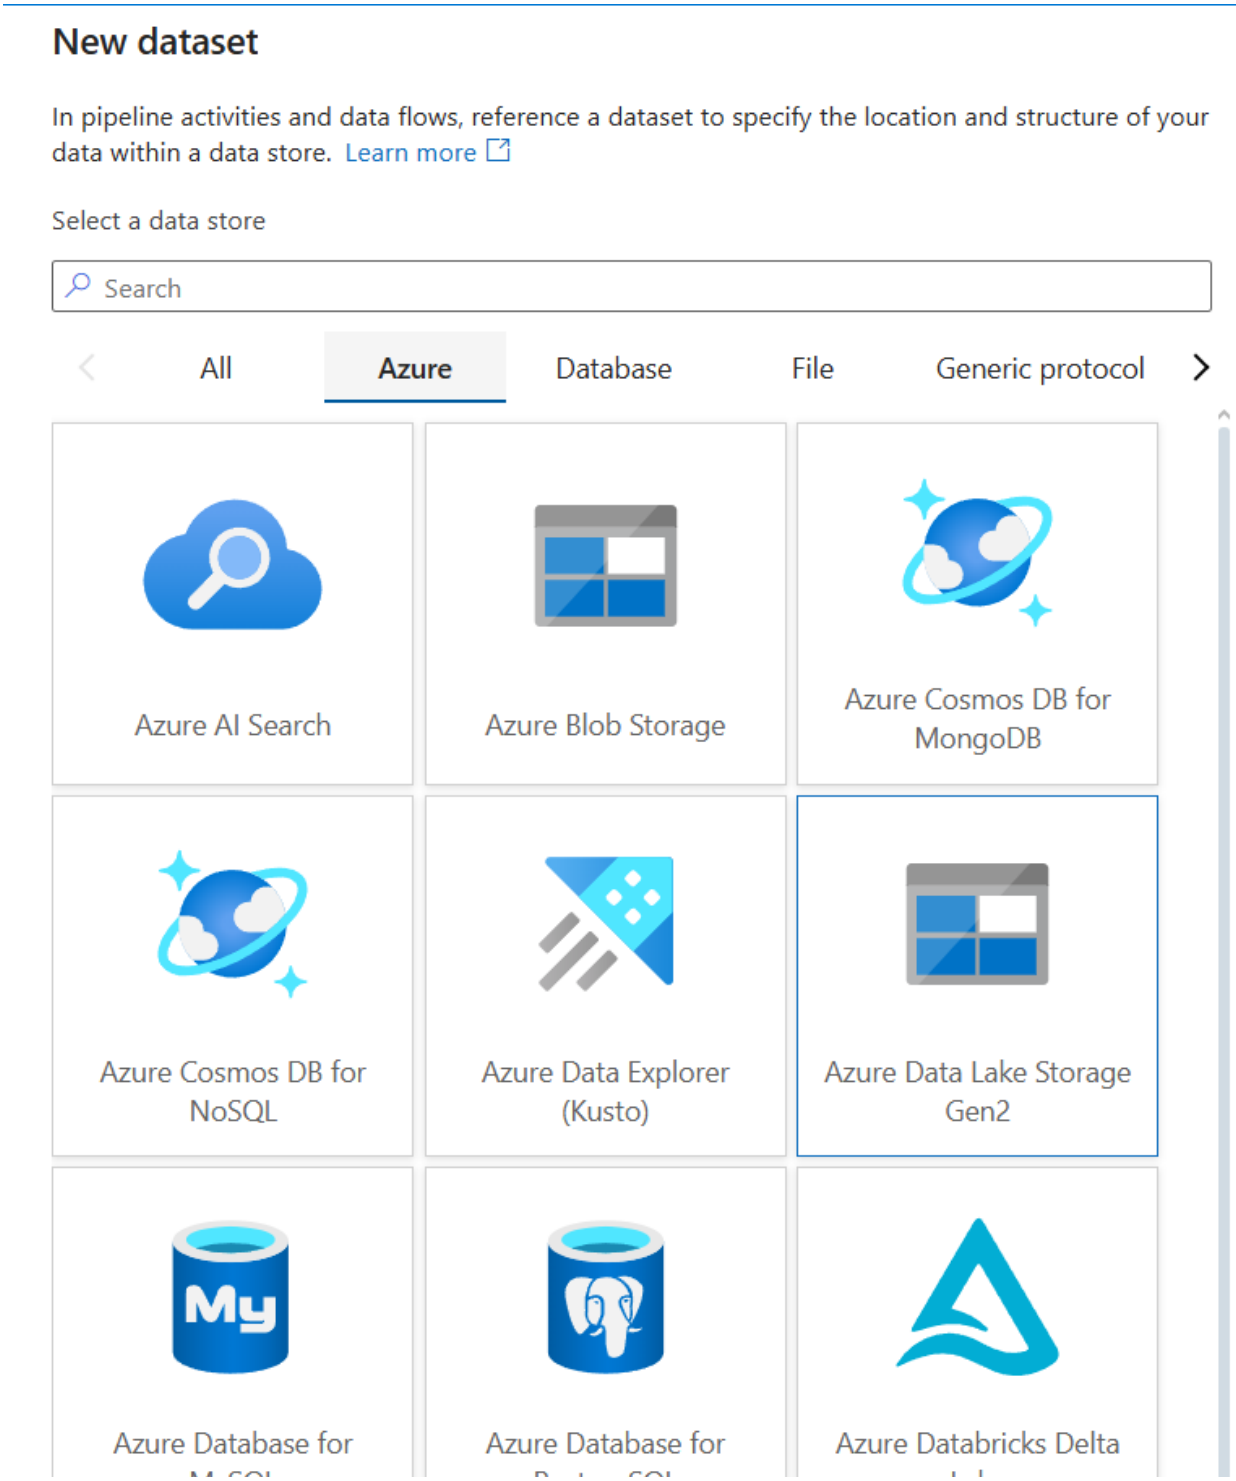

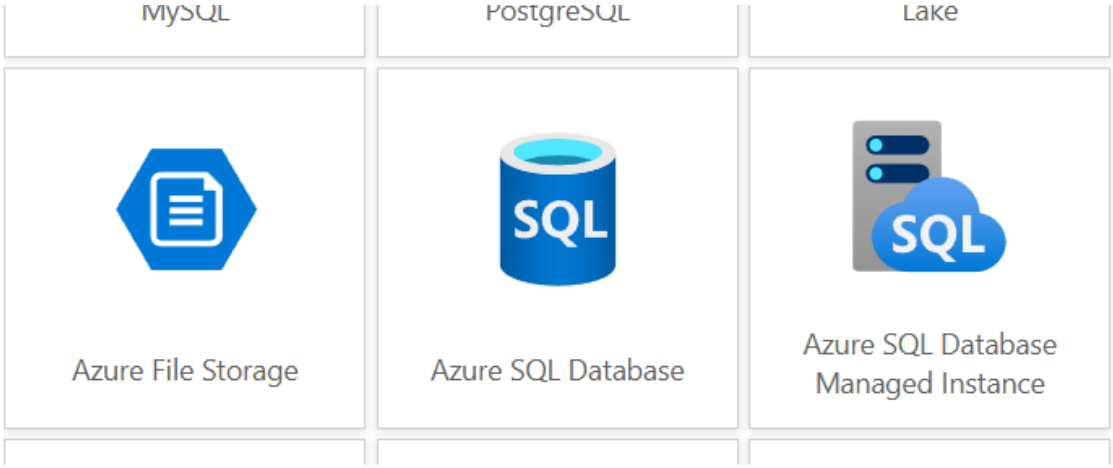

Continue Cancel

Select format

Choose the format type of your data

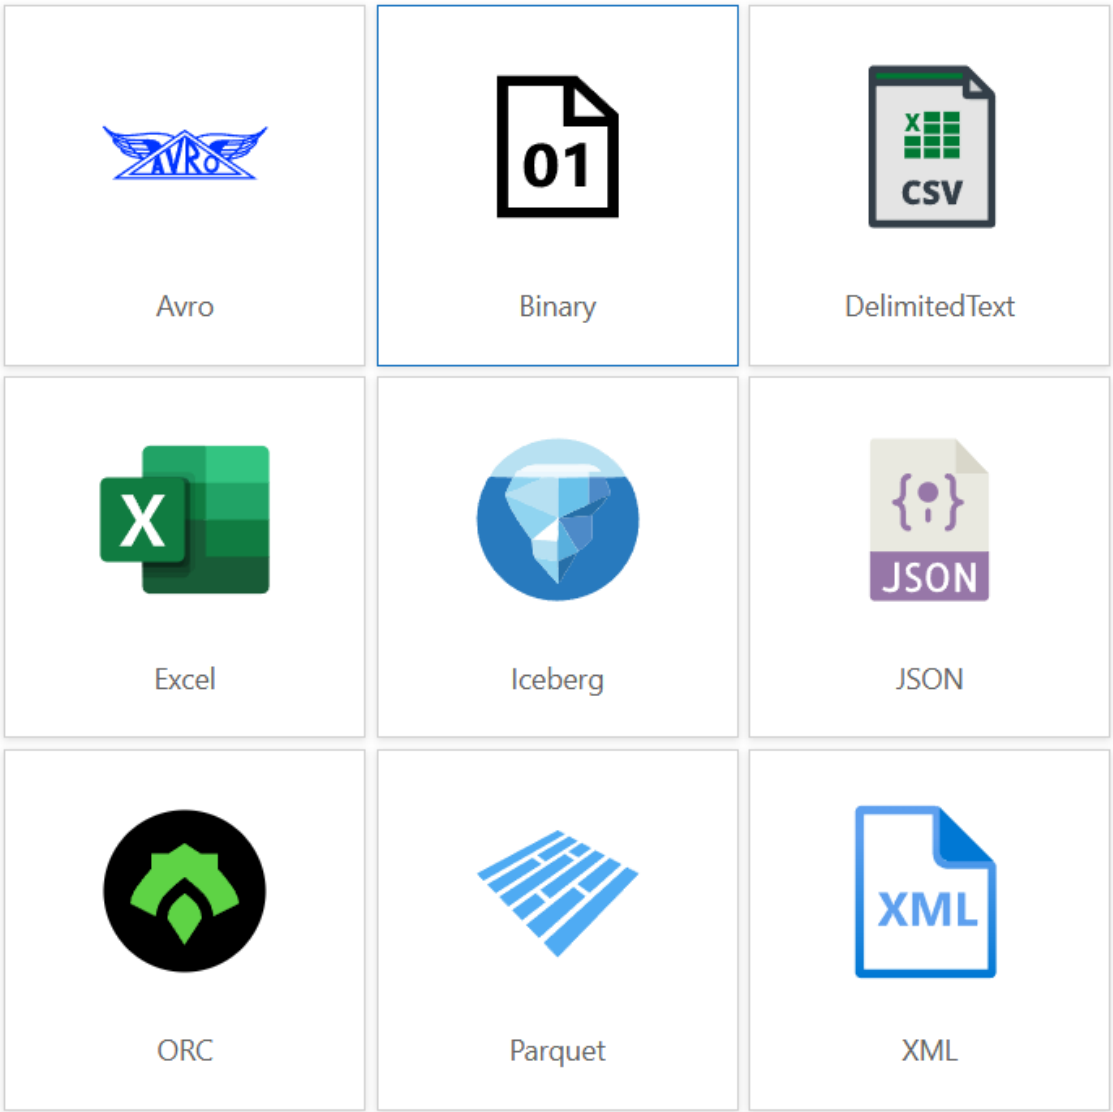


Continue
Back
Cancel
Set properties
Name
DS_Lakehouse_Images
Linked service *
AzureDataLakeStorage1
File path
raw
/
imagenes
/
File name

3.5. Creación del Pipeline de Carga (Copy Data Activity)

El Pipeline (ej., `PL_Migrar_Datos_FER`) debe orquestar dos tareas de copia distintas y paralelas para manejar los dos tipos de datos desde sus orígenes en la nube hasta el Data Lakehouse (ADLS Gen2).

1. **Crear Pipeline:** Se crea un nuevo Pipeline en ADF Studio (ej., `PL_Migrar_Datos_FER`).
2. **Añadir Dos Actividades de Copia de Datos:** Se incluyen dos actividades de *Copy Data* independientes.

1. Flujo de Embeddings (PostgreSQL a Parquet)

Esta actividad traslada los vectores numéricos y metadatos desde la base de datos a un formato analítico optimizado, corrigiendo dinámicamente la ruta del archivo (filepath) para que coincida con la ubicación final de las imágenes en el Data Lakehouse.

- **Nombre de Actividad:** `Copy_Embeddings_PostgreSQL`
- **Configuración de Origen (Source):** Se utiliza el Dataset de origen (`DS_PgVector_ImagenesFer`), pero debes cambiar el modo de extracción de **"Table"** a **"Query"**.
- **Consulta SQL de Extracción (Transformación de Ruta):**
  - Introduce la siguiente consulta en el campo "Query". Esta consulta concatena el prefijo de la ruta y le da un alias (`filepath_corregido`) a la columna resultante.

```
SELECT
    id,
    emotion,
    vector,
    -- CAMBIO CLAVE: Concatena el prefijo de la ruta del Data Lakehouse
    'raw/imagenes/train/' || filepath AS filepath
FROM
    public.imagenes_fer;
```

- **Configuración de Destino (Sink):** Se utiliza el Dataset de destino (`DS_Lakehouse_Embeddings`) configurado con el formato **Parquet**.
- **Manejo de Vectores:** ADF gestiona la conversión de la columna `VECTOR(512)` de PostgreSQL en un tipo de dato compatible (como una *array* o *string* serializada) dentro del archivo Parquet.
- **Mapeo (Mapping):** Dentro de la actividad Copy Data, ve a la pestaña "Mapping" y asegúrate de que la columna de origen `filepath_corregido` (generada por la consulta SQL) se mapee correctamente a la columna destino `filepath` del archivo Parquet.

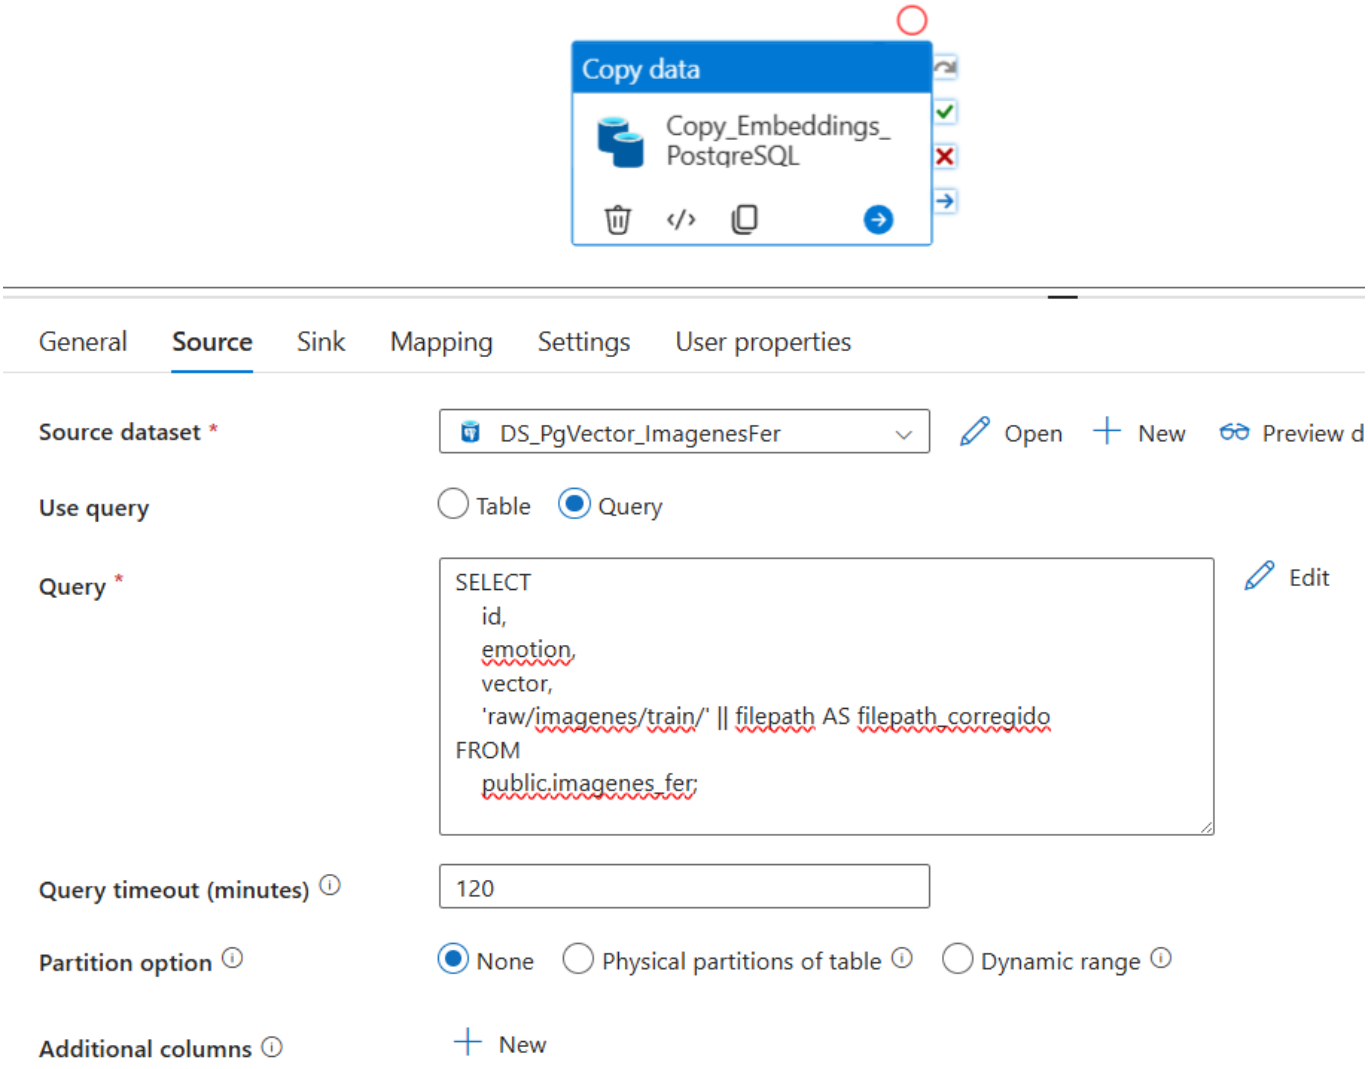

2. Flujo de Imágenes (Blob Storage a Binary)

Esta actividad traslada los archivos de imagen binarios sin alteración a la zona de datos crudos (raw) del Data Lakehouse.

- **Nombre de Actividad:** `Copy_Images_BlobStorage`
- **Configuración de Origen (Source):** Se utiliza el Dataset de origen binario (`DS_Images_Source`), conectado al Linked Service de Azure Blob Storage (3.2.3).
- **Configuración de Destino (Sink):** Se utiliza el Dataset de destino binario (`DS_Lakehouse_Images`) configurado con el formato **Binary**.

- **Comportamiento de Copia:** Es crucial configurar esta actividad para que preserve la jerarquía de las carpetas, `Preserve hierarchy` (ej., `train/feliz/`) al copiar de Blob Storage al Data Lakehouse, garantizando que los `filepaths` de los embeddings sigan siendo válidos.

3.6. Ejecución y Monitoreo

Esta fase valida la corrección de rutas, la conexión Cloud-to-Cloud y el éxito del traslado de datos vectoriales y binarios al Data Lakehouse.

1. Verificación del Flujo (Modo Debug)

- **Propósito:** Asegurar que ambas actividades de copia (`Copy_Embeddings_PostgreSQL` y `Copy_Images_BlobStorage`) se ejecuten sin errores.
- **Ejecución:** Inicia el Pipeline en modo **"Debug"** (Depurar) para una prueba de validación.
- **Validación de Embeddings:** Confirma el estado "Succeeded" y verifica en los detalles que el **número de filas leídas** de PostgreSQL sea correcto. Esto valida que la **Source Query** que corrige el `filepath` funciona.
- **Validación de Imágenes:** Confirma el estado "Succeeded" y verifica el **volumen de datos (Bytes)** copiados de Azure Blob Storage. Esto valida que la conexión Cloud-to-Cloud es exitosa.

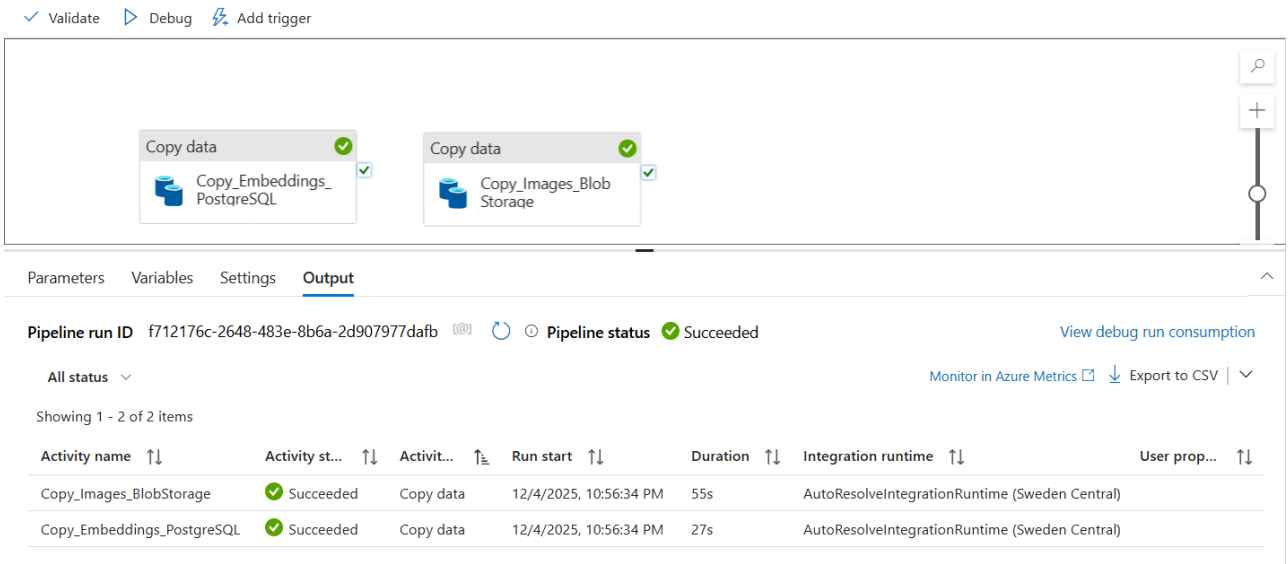

2. Programación de la Carga (Triggers)

- **Publicación:** Haz clic en **"Publish all"** (Publicar todo) antes de programar la ejecución.
- **Trigger:** Vamos a ir a **"Add Trigger"** y le vamos a dar clic a **"Trigger Now"**

3. Monitoreo y Validación de Destino

- **Panel de Monitoreo:** En la pestaña "Monitor" de ADF, revisa el estado de la ejecución (debe ser **"Succeeded"**).

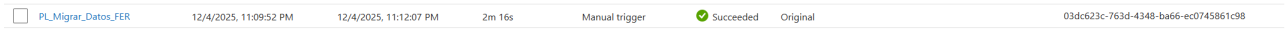

- **Validación de Destino (ADLS Gen2):**

- Verifica que los archivos **Parquet** (Embeddings) se hayan creado en la ruta: `raw/embeddings/fer2013/`.
- Verifica que los archivos **Binarios** (Imágenes) se hayan creado en la ruta: `raw/images/fer2013/train/` y que se haya **mantenido la jerarquía de las carpetas de emoción** (gracias a la configuración 'Preserve hierarchy').

4. Conexion de Microsoft AI Foundry al Datalake

Esta es la fase final, donde los datos vectoriales (embeddings) y las imágenes binarias se utilizan para construir aplicaciones de Inteligencia Artificial.

1. Desplegar Microsoft AI Foundry

El despliegue de **Microsoft AI Foundry** (o el servicio específico de Azure AI) consiste en configurar el entorno para acceder y procesar los datos en el Data Lakehouse.

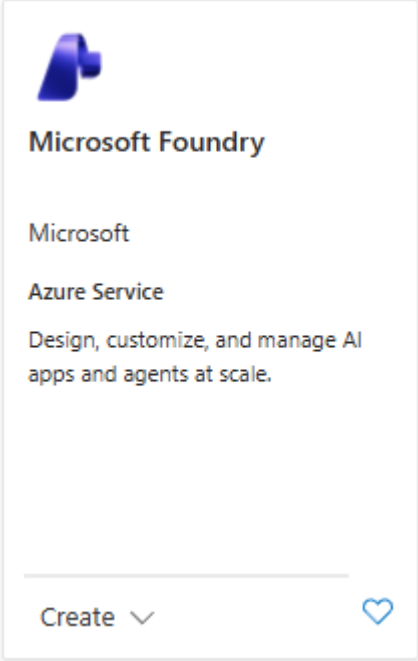

- **Configuración del Acceso:** El servicio Foundry se configura con acceso de lectura directo al **Data Lakehouse (ADLS Gen2)** para obtener los datos.
- **Indexación:** Los **vectores** leídos desde los archivos Parquet (`raw/embeddings/fer2013/`) se cargan en un índice vectorial optimizado (ej., Azure AI Search o un índice vectorial nativo de Foundry). Esto permite realizar consultas de similitud ultrarrápidas, que son esenciales para el consumo de embeddings.

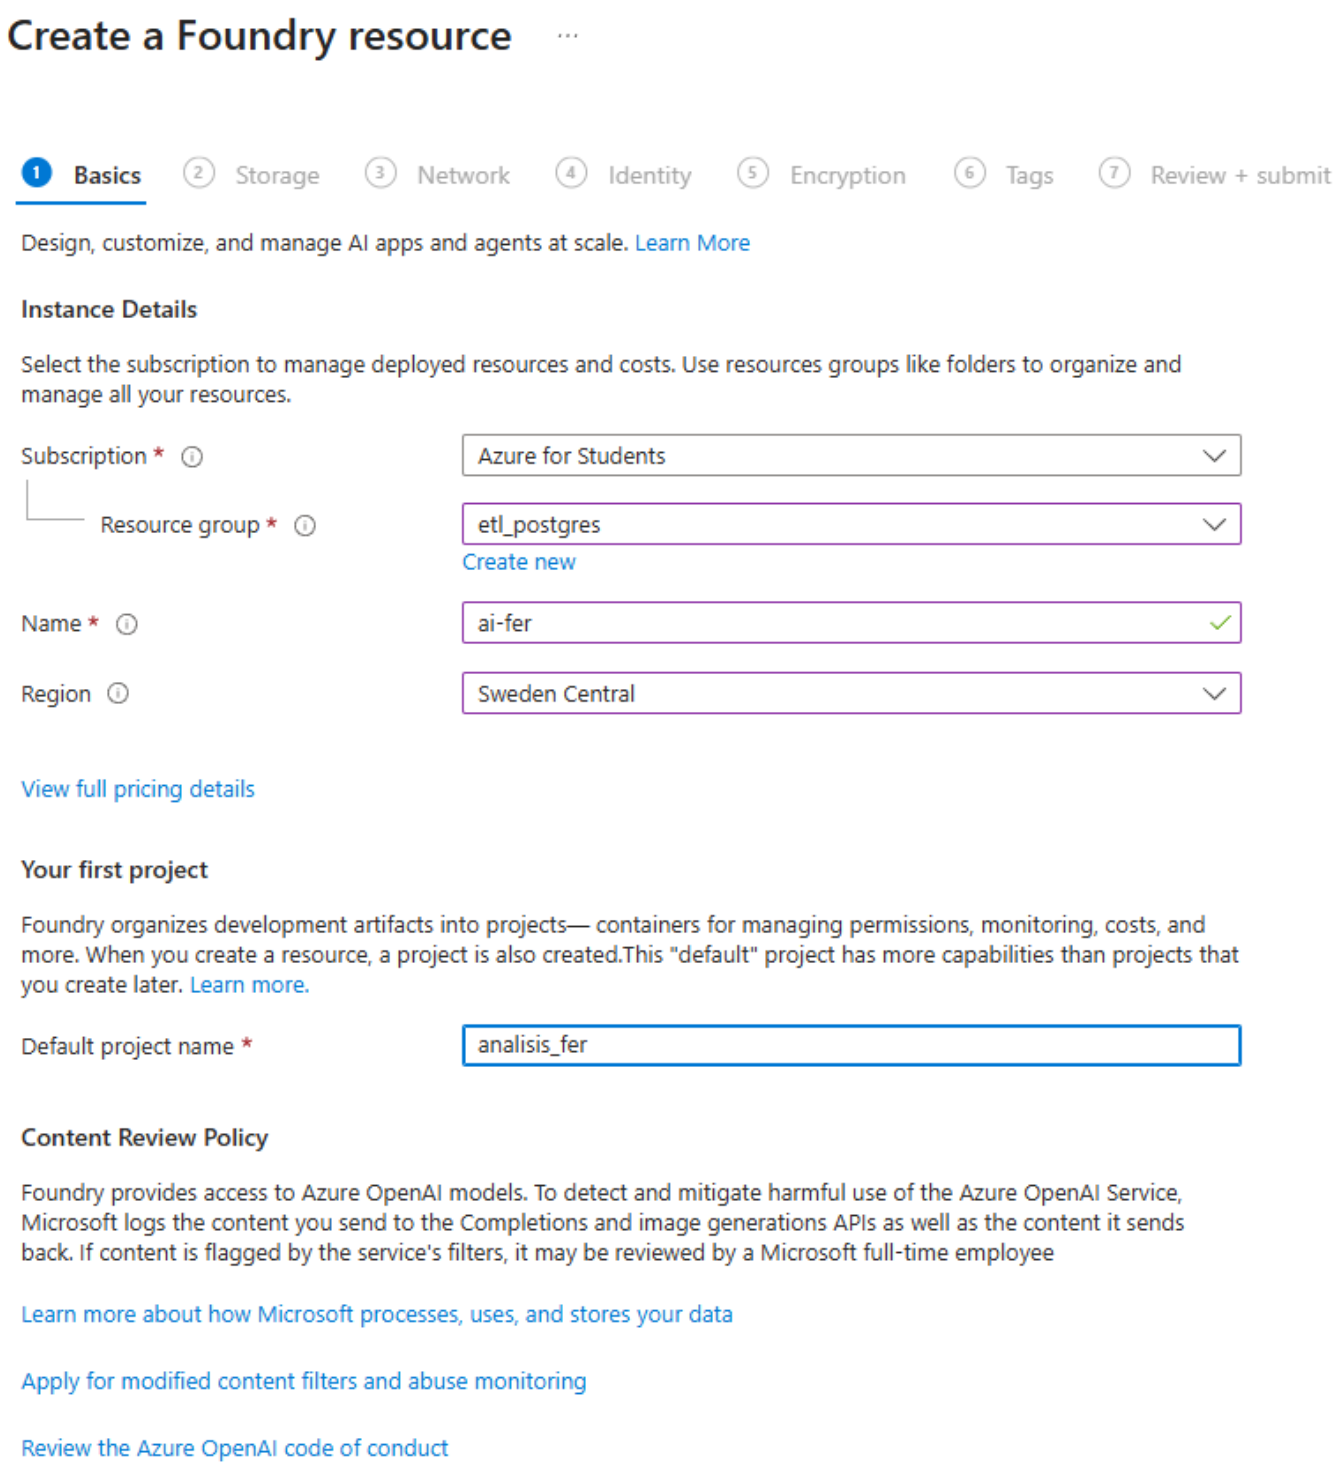

Para conectar con nuestro Datalake vamos a ir a `Centro de Administración`, `Connected resources`, seleccionamos `Nueva conexión`.

Busca y selecciona el tipo de conexión apropiado, como Storage account (Cuenta de almacenamiento).

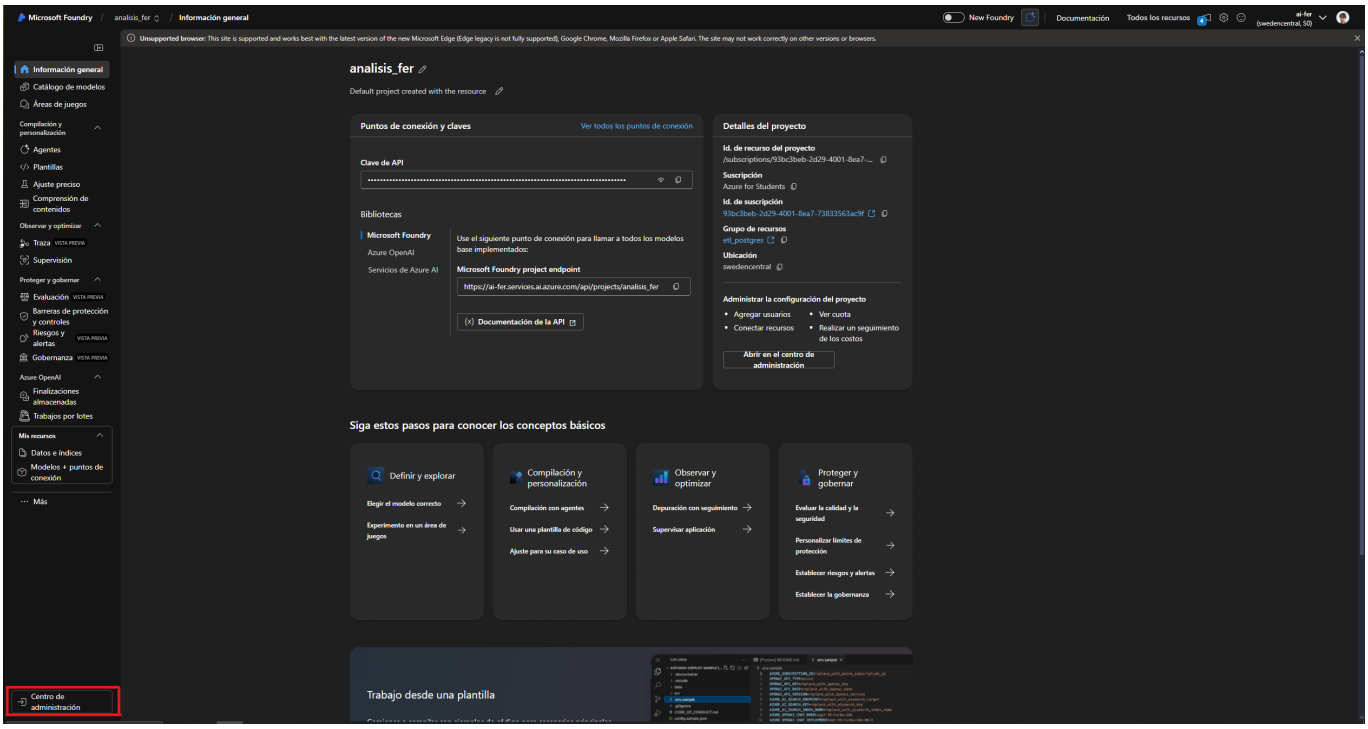
Microsoft Foundry
analisis_fer
Información general
Unsupported browser: This site is supported and works best with the latest version of the new Microsoft Edge (Edge legacy is not fully supported), Google Chrome, Mozilla Firefox or Apple Safari. The site may not work correctly on other versions or browsers.
New Foundry
Documentación
Todos los recursos
Información general
Catálogo de modelos
Áreas de juegos
Compilación y personalización
Agentes
Plantillas
Ajuste preciso
Comprensión de contenidos
Observar y optimizar
Traza
Supervisión
Proteger y gobernar
Evaluación
Barreras de protección y controles
Riesgos y alertas
Gobernanza
Azure OpenAI
Finalizaciones almacenadas
Trabajos por lotes
Mis recursos
Datos e índices
Modelos + puntos de conexión
Más
Centro de administración
analisis_fer
Default project created with the resource
Puntos de conexión y claves
Ver todos los puntos de conexión
Clave de API
Bibliotecas
Microsoft Foundry
Azure OpenAI
Servicios de Azure AI
Use el siguiente punto de conexión para llamar a todos los modelos base implementados:
Microsoft Foundry project endpoint
https://ai-fer.services.ai.azure.com/api/projects/analisis_fer
Documentación de la API
Detalles del proyecto
Id. de recurso del proyecto
/subscriptions/93bc3beb-2d29-4001-8ea7-...
Suscripción
Azure for Students
Id. de suscripción
93bc3beb-2d29-4001-8ea7-73833563ac9f
Grupo de recursos
etl_postgres
Ubicación
swedencentral
Administrar la configuración del proyecto
Agregar usuarios
Ver cuota
Conectar recursos
Realizar un seguimiento de los costos
Abrir en el centro de administración
Siga estos pasos para conocer los conceptos básicos
Definir y explorar
Elegir el modelo correcto
Experimento en un área de juegos
Compilación y personalización
Compilación con agentes
Usar una plantilla de código
Ajuste para su caso de uso
Observar y optimizar
Depuración con seguimiento
Supervisar aplicación
Proteger y gobernar
Evaluar la calidad y la seguridad
Personalizar límites de protección
Establecer riesgos y alertas
Establecer la gobernanza
Trabajo desde una plantilla

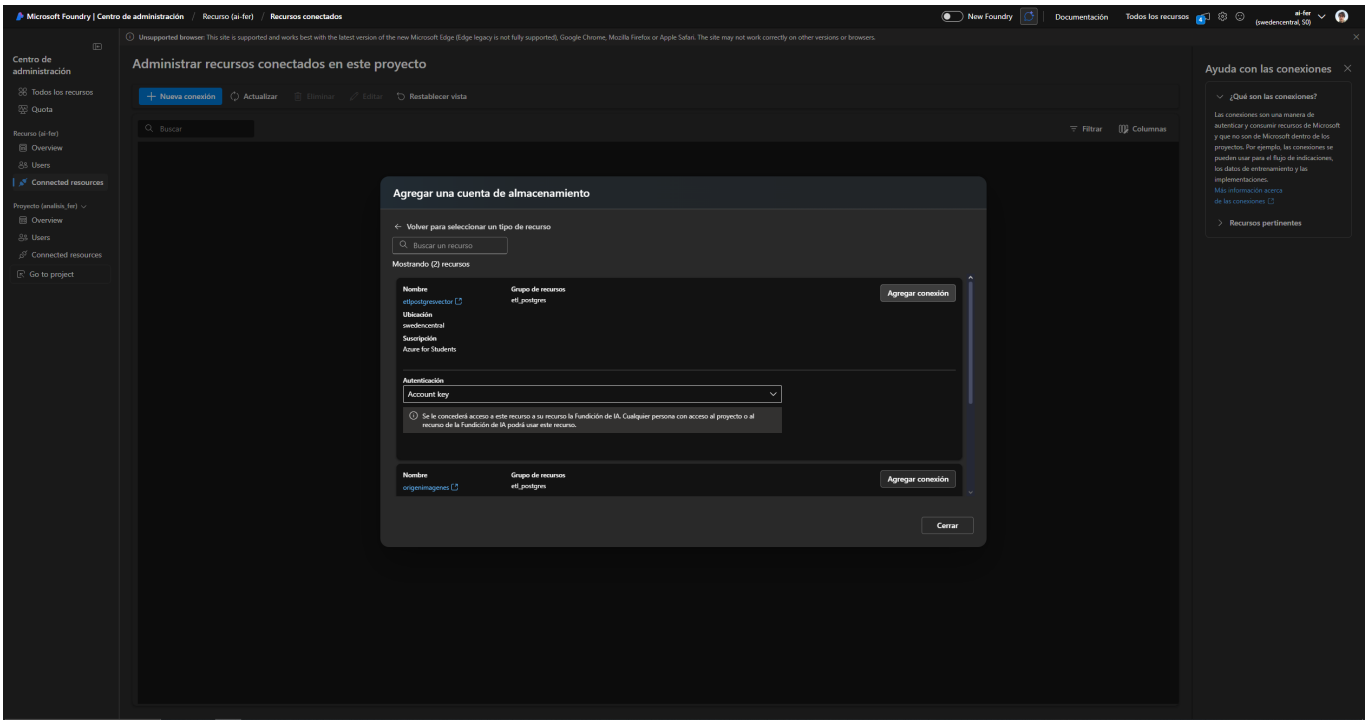
Microsoft Foundry | Centro de administración
Recurso (ai-fer)
Recursos conectados
Unsupported browser: This site is supported and works best with the latest version of the new Microsoft Edge (Edge legacy is not fully supported), Google Chrome, Mozilla Firefox or Apple Safari. The site may not work correctly on other versions or browsers.
New Foundry
Documentación
Todos los recursos
Centro de administración
Todos los recursos
Quota
Recurso (ai-fer)
Overview
Users
Connected resources
Proyecto (analisis_fer)
Overview
Users
Connected resources
Go to project
Administrar recursos conectados en este proyecto
Nueva conexión
Actualizar
Eliminar
Editar
Restablecer vista
Buscar
Filtrar
Columnas
Agregar una cuenta de almacenamiento
Volver para seleccionar un tipo de recurso
Buscar un recurso
Mostrando (2) recursos
Nombre
etlpostgresvector
Grupo de recursos
etl_postgres
Ubicación
swedencentral
Suscripción
Azure for Students
Agregar conexión
Autenticación
Account key
Se le concederá acceso a este recurso a su recurso la Fundición de IA. Cualquier persona con acceso al proyecto o al recurso de la Fundición de IA podrá usar este recurso.
Nombre
origenimagenes
Grupo de recursos
etl_postgres
Agregar conexión
Cerrar
Ayuda con las conexiones
¿Qué son las conexiones?
Las conexiones son una manera de autenticar y consumir recursos de Microsoft y que no son de Microsoft dentro de los proyectos. Por ejemplo, las conexiones se pueden usar para el flujo de indicaciones, los datos de entrenamiento y las implementaciones.
Más información acerca de las conexiones
Recursos pertinentes